

Synergy Vision

Series de Tiempo en R



Índice general

| | |
|---|-------------|
| Índice de cuadros | V |
| Índice de figuras | VII |
| Prefacio | IX |
| Información sobre los programas y convenciones | IX |
| Acerca del Autor | XI |
| Introducción | XIII |
| 0.1. Conceptos básicos | XIX |
| 0.2. Ejemplos | XIX |
| 0.2.1. Clasificación de las series de tiempo | XXIV |
| 0.3. Componentes de una serie de tiempo | XXVI |
| 0.3.1. El Modelo Aditivo de Componentes de Series de Tiempo | XXVII |
| 0.3.2. El Modelo Multiplicativo de Componentes de Series de Tiempo | XXIX |
| 0.4. Estimación de la Tendencia | XXX |
| 0.4.1. Eliminación de la tendencia en ausencia de estacionalidad | XXXIII |
| 0.5. Eliminación de la tendencia y la estacionalidad . . . | XL |
| Características de series de tiempo | XLV |
| 0.6. Medidas de dependencia para series de tiempo . . . | XLV |
| 0.7. Estimación de la Tendencia | LV |
| 0.7.1. Estimación de la tendencia en ausencia de estacionalidad | LIX |



Índice de cuadros



Índice de figuras



Prefacio



La versión en línea de este libro se comparte bajo la licencia Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International License¹.

¿Por qué leer este libro?

Estructura del libro

Información sobre los programas y convenciones

Este libro es posible gracias a una gran cantidad de desarrolladores que contribuyen en la construcción de herramientas para generar documentos enriquecidos e interactivos. En particular al autor de los paquetes Yihui Xie xie2015.

¹<http://creativecommons.org/licenses/by-nc-sa/4.0/>

Prácticas interactivas con R

Vamos a utilizar el paquete Datacamp Tutorial² que utiliza la librería en JavaScript Datacamp Light³ para crear ejercicios y prácticas con R. De esta forma el libro es completamente interactivo y con prácticas incluidas. De esta forma estamos creando una experiencia única de aprendizaje en línea.

eyJ5YW5ndWFnZSI6InIiLCJwcmVfZXhlcmlNpc2VfY29kZSI6ImIgPC0gNSIsInNhbXBsZSI6Il

Agradecimientos

Synergy Vision, Caracas, Venezuela

²<https://github.com/datacamp/tutorial>

³<https://github.com/datacamp/datacamp-light>

Acerca del Autor

Este material es un esfuerzo de equipo en Synergy Vision, (<http://synergy.vision/nosotros/>).

El propósito de este material es ofrecer una experiencia de aprendizaje distinta y enfocada en el estudiante. El propósito es que realmente aprenda y practique con mucha intensidad. La idea es cambiar el modelo de clases magistrales y ofrecer una experiencia más centrada en el estudiante y menos centrado en el profesor. Para los temas más técnicos y avanzados es necesario trabajar de la mano con el estudiante y asistirlo en el proceso de aprendizaje con prácticas guiadas, material en línea e interactivo, videos, evaluación continua de brechas y entendimiento, entre otros, para procurar el dominio de la materia.

Nuestro foco es la Ciencia de los Datos Financieros y para ello se desarrollará material sobre: **Probabilidad y Estadística Matemática en R, Programación Científica en R, Mercados, Inversiones y Trading, Datos y Modelos Financieros en R, Renta Fija, Inmunización de Carteras de Renta Fija, Teoría de Riesgo en R, Finanzas Cuantitativas, Ingeniería Financiera, Procesos Estocásticos en R, Series de Tiempo en R, Ciencia de los Datos, Ciencia de los Datos Financieros, Simulación en R, Desarrollo de Aplicaciones Interactivas en R, Minería de Datos, Aprendizaje Estadístico, Estadística Multivariante, Riesgo de Crédito, Riesgo de Liquidez, Riesgo de Mercado, Riesgo Operacional, Riesgo de Cambio, Análisis Técnico, Inversión Visual, Finanzas, Finanzas Corporativas, Valoración, Teoría de Portafolio**, entre otros.

Nuestra cuenta de Twitter es (<https://twitter.com/>

[bysynergyvision](https://github.com/synergyvision)) y nuestros repositorios están en GitHub (<https://github.com/synergyvision>).

Somos Científicos de Datos Financieros

0

Introducción

Las series de tiempo ya han desempeñado un papel importante en las primeras ciencias naturales. La astronomía babilónica utilizó series de tiempo de las posiciones relativas de estrellas y planetas para predecir eventos astronómicos. Las observaciones de los movimientos de los planetas formaron la base de las leyes que Johannes Kepler descubrió. El análisis de las series de tiempo ayuda a detectar las regularidades en las observaciones de una variable y a derivar “leyes” de ellas, y/o explotar toda la información incluida en esta variable para predecir mejor los desarrollos futuros. La idea metodológica básica detrás de estos procedimientos, que también eran válidos para los babilonios, es que es posible descomponer series de tiempos en un número finito de componentes independientes pero no directamente observables que se desarrollan regularmente y que por lo tanto pueden ser calculados de antemano. Para este procedimiento es necesario que existan diferentes factores independientes que incidan en la variable. A mediados del siglo XIX, este enfoque metodológico de la astronomía fue asumido por los economistas Charles Babbage y William Stanley Jevons. La descomposición en componentes no observados que dependen de diferentes factores causales, como suele emplearse en el análisis clásico de series de tiempo, fue desarrollada por Warren M. Persons (1919). Distinguía cuatro componentes diferentes:

- Desarrollo a largo plazo, tendencia,
- Componente cíclico con períodos de más de un año, el ciclo económico,
- Componente que contiene los altibajos dentro de un año, el ciclo estacional, y

- Componente que contiene todos los movimientos que no pertenecen ni a la tendencia ni al ciclo económico ni al componente estacional, el residual.

Suponiendo que los diferentes factores no observables son independientes, su recubrimiento aditivo genera las series de tiempo que, sin embargo, sólo podemos observar en su conjunto. Para obtener información sobre el proceso de generación de datos, tenemos que hacer suposiciones sobre sus componentes no observados. El análisis clásico de series de tiempo supone que los componentes sistemáticos, es decir, la tendencia, el ciclo económico y el ciclo estacional, no están influenciados por perturbaciones estocásticas y, por lo tanto, pueden representarse mediante funciones determinísticas del tiempo. El impacto estocástico se limita a los residuos, que, por otra parte, no contienen movimientos sistemáticos. Por lo tanto, se modela como una serie de variables aleatorias independientes o no correlacionadas con esperanza cero y varianza constante, es decir, como un proceso aleatorio puro.

Este enfoque cambió desde la presentación de los trabajos de George E. P. Box and Gwilym M. Jenkins, “Time Series Analysis: Forecasting and Control”, en los años 70 del siglo pasado. Se abandonaron los procedimientos puramente descriptivos del análisis clásico de series de tiempo y, en su lugar, se han utilizado los resultados y métodos de la teoría de la probabilidad y las estadísticas matemáticas. Desde ese entonces, el análisis de series ha tenido un desarrollo creciente. Se han presentado una gran variedad de libros sobre este tópico, cada uno de ellos influenciado principalmente por la orientación de las series que se discuten en sus contenidos. Una gran parte de la literatura está dirigida a exponer los aspectos teóricos alrededor de las series de tiempo, siendo en muchos casos, rigurosamente desarrollados y descritos, sin embargo poco de ellos presentan implementaciones de las técnicas estudiadas y su comprensión en ejemplos reales lo que a veces puede dificultar su comprensión en especial para aquellos que no posean una apropiada formación matemática.

Los primeros intentos de estudiar el comportamiento de las series de tiempo financieras fueron realizados por profesionales financieros

y periodistas en lugar de por académicos. De hecho, esto parece haberse convertido en una tradición de larga data, ya que, incluso hoy en día, gran parte de la investigación y el desarrollo empíricos todavía se originan en la propia industria financiera. Esto puede explicarse por el carácter práctico de los problemas, la necesidad de datos especializados y las posibles ventajas de dicho análisis. El primer y más conocido ejemplo de la investigación publicada sobre series de tiempo financieras es el legendario Charles Dow, como se expresa en sus editoriales en el *Wall Street Times* entre 1900 y 1902. Estos escritos formaron la base de la “teoría del Dow” e influyeron en lo que más tarde se conoció como análisis técnico y carisma. Aunque Dow no coleccionó y publicó sus editoriales por separado, esto fue hecho póstumamente por su seguidor Samuel Nelson (Nelson, 1902). Las ideas originales de Dow fueron posteriormente interpretadas y ampliadas por Hamilton (1922) y Rhea (1932). Estas ideas gozaron de cierto reconocimiento entre los académicos de la época: por ejemplo, Hamilton fue elegido miembro de la *Royal Statistical Society*.

Aunque Dow y sus seguidores discutieron muchas de las ideas que encontramos en el análisis moderno de finanzas y series de tiempo, incluyendo estacionalidad, eficiencia del mercado, correlación entre rendimiento de activos e índices, diversificación e imprevisibilidad, no hicieron ningún esfuerzo serio para adoptar métodos estadísticos formales. La mayor parte del análisis empírico consistió en la interpretación minuciosa de gráficos detallados de las medias bursátiles sectoriales, formando así los famosos índices Dow-Jones. Se argumentó que estos índices descuentan toda la información necesaria y proporcionan el mejor pronóstico de eventos futuros. Una idea fundamental, muy relevante para la teoría de los ciclos de Stanley Jevons y la metodología de descomposición de tendencias de la “curva Harvard A-B-C” de Warren Persons, fue que las variaciones de precios del mercado consistían en tres movimientos primarios: diarios, a medio y largo plazo.

La investigación empírica más temprana que utiliza métodos estadísticos formales se remonta a los documentos de Working (1934), Cowles (1933,1944) y Cowles and Jones (1937). El trabajo cen-

tró la atención en una característica previamente señalada de los precios de las materias primas y las acciones: que se asemejan a la acumulación de cambios puramente aleatorios. Alfred Cowles 3rd, analista financiero cuantitativamente entrenado y fundador de Econometric Society and the Cowles Foundation, investigó la habilidad de los analistas de mercado y servicios financieros para predecir los futuros cambios de precios, encontrando que había pocas pruebas de que pudieran hacerlo. Cowles y Jones reportaron evidencia de correlación positiva entre sucesivas variaciones de precios, pero, como posteriormente Cowles (1960) comentó, esto fue probablemente debido a que tomaron promedios mensuales de precios diarios o semanales antes de computar los cambios: un fenómeno de “correlación espuria”, analizado por Working (1960).

La previsibilidad de los cambios de precios se ha convertido desde entonces en un tema importante de la investigación financiera, pero, sorprendentemente, poco más se publicó hasta el estudio de Kendall (1953), en el que encontró que los cambios semanales en una amplia variedad de precios financieros no podían predecirse ni a partir de los cambios pasados en las series ni a partir de los cambios pasados en otras series de precios. Este parece haber sido el primer informe explícito de esta propiedad de los precios financieros a menudo citada, aunque la investigación sobre la previsibilidad de los precios sólo se vio impulsada por la publicación de los documentos de Roberts (1959) y Osborne (1959). El primero presenta un argumento en gran medida heurístico sobre por qué las sucesivas variaciones de precios deben ser independientes, mientras que el segundo desarrolla la proposición de que no se trata de cambios absolutos de precios, sino de cambios logarítmicos de precios independientes entre sí. Con la suposición auxiliar de que las propias modificaciones se distribuyen normalmente, esto implica que los precios se generan como movimiento Browniano.

El análisis de series de tiempo desempeña un papel importante en el análisis requerido para el pronóstico de eventos futuros. Existen varias formas o métodos de calcular cual va a ser la tendencia del comportamiento del proceso en estudio.

Un **pronóstico** es una predicción de algún evento o eventos futuros.

Como sugirió Neils Bohr, hacer buenas predicciones no siempre es fácil. Los pronósticos famosamente “malos” incluyen lo siguiente del libro *“Malas Predicciones”*:

- “La población es de tamaño constante y se mantendrá hasta el fin de la humanidad.” La Enciclopedia, 1756.
- “1930 será un espléndido año de empleo.” Departamento de Trabajo de los EE. UU., pronóstico de Año Nuevo en 1929, justo antes de que el mercado se desplomara el 29 de octubre.
- “Las computadoras se multiplican a un ritmo rápido. Para el cambio de siglo habrá 220,000 en los EE. UU.” Wall Street Journal, 1966.

Algunos ejemplos donde se puede utilizar y hacer precciones con series de tiempo:

- 1) **Dirección de Operaciones.** Las organizaciones empresariales utilizan habitualmente las previsiones de ventas de productos o la demanda de servicios para programar la producción, controlar los inventarios, gestionar la cadena de suministro, determinar las necesidades de personal y planificar la capacidad. Las previsiones también pueden utilizarse para determinar la combinación de productos o servicios que deben ofrecerse y las ubicaciones en las que deben fabricarse los productos.
- 2) **Marketing.** La previsión es importante en muchas decisiones de marketing. Las previsiones de respuesta de las ventas a los gastos publicitarios, las nuevas promociones o los cambios en las políticas de precios permiten a las empresas evaluar su eficacia, determinar si se están alcanzando los objetivos y realizar ajustes.
- 3) **Finanzas y Gestión de Riesgos.** Los inversores en activos financieros están interesados en pronosticar los rendimientos de sus inversiones. Estos activos incluyen, pero no se limitan a acciones, bonos y materias primas; otras decisiones de inversión se pueden tomar en relación con las

previsiones de tasas de interés, opciones y tipos de cambio. La gestión del riesgo financiero requiere previsiones de la volatilidad de la rentabilidad de los activos para que se puedan evaluar y asegurar los riesgos asociados a las carteras de inversión, y para que los derivados financieros puedan cotizarse adecuadamente.

- 4) **Economía.** Los gobiernos, las instituciones financieras y las organizaciones de política requieren pronósticos de las principales variables económicas, como el producto interno bruto, el crecimiento demográfico, el desempleo, las tasas de interés, la inflación, el crecimiento del empleo, la producción y el consumo. Estas previsiones son parte integrante de la orientación de la política monetaria y fiscal, así como de los planes y decisiones presupuestarias adoptadas por los gobiernos. También son fundamentales en las decisiones de planificación estratégica tomadas por organizaciones empresariales e instituciones financieras.
- 5) **Control de Procesos Industriales.** Las previsiones de los valores futuros de las características de calidad crítica de un proceso de producción pueden ayudar a determinar cuándo deben cambiarse las variables controlables importantes del proceso, o si el proceso debe detenerse y revisarse. Los esquemas de retroalimentación y control feedforward son ampliamente utilizados en el monitoreo y ajuste de procesos industriales, y las predicciones de la producción del proceso son una parte integral de estos esquemas.
- 6) **Demografía.** Las previsiones de población por país y región se realizan de manera rutinaria, a menudo estratificadas por variables como el género, la edad y la raza. Los demógrafos también pronostican nacimientos, muertes y patrones migratorios de las poblaciones. Los gobiernos utilizan estas previsiones para planificar políticas y acciones de servicio social, como el gasto en atención médica, programas de jubilación y programas de lucha contra la pobreza. Muchas empresas utilizan pronósticos de pobla-

ciones por grupos de edad para hacer planes estratégicos en relación con el desarrollo de nuevas líneas de productos o tipos de servicios que será ofrecido.

0.1. Conceptos básicos

Una serie tiempo es una secuencia de observaciones, medidos en determinados momentos del tiempo, ordenados cronológicamente y, espaciados entre sí de manera uniforme, así los datos usualmente son dependientes entre sí. El principal objetivo de una serie de tiempo es su análisis para hacer pronóstico. Formalmente se tiene la siguiente definición.

Definición 0.1. Una **serie de tiempo** es un conjunto de observaciones x_t , cada una registrada a un tiempo específico t .

Definición 0.2. Un **modelo de series de tiempo** para los datos observados $\{x_t\}$ es una especificación de una distribución conjunta (o posiblemente solo de medias y covarianzas) de una sucesión de variables aleatorias $\{X_t\}$ de las cuales $\{x_t\}$ es una realización.


A continuación presentaremos una serie de ejemplos que demuestran la utilidad y lo cotidiano de las series de tiempo, también se mostrarán los códigos en R para cargar los archivos de datos y graficar las respectivas series de tiempo.

0.2. Ejemplos

Ejemplo 0.1. Beneficios de acciones. Beneficios por acción trimestrales para la compañía Johnson & Johnson. Se tienen 84 trimestres iniciando el primer trimestre de 1960 hasta el último trimestre de 1980. Los métodos para analizar tales datos se verán en el Tema 3 usando técnicas de regresión. El archivo es “*jj.txt*”.


Los comandos en R para cargar el archivo y graficar la serie de tiempo son los siguientes:

```
jj=ts(scan("data/jj.txt"),start=1960,freq=4)
plot(jj, type="l",ylab="Beneficios por acción trimestrales")
```




Ejemplo 0.2. El archivo “*ReservasInternacionales.xlsx*”, contiene el registro mensual de Reservas Internacionales Venezolanas en millones de dólares (\$), iniciando en el mes de enero de 1996 hasta el mes de diciembre de 2017

```
#library(readxl)
reservas <- read_excel("data/ReservasInternacionales.xlsx")
reservas=ts(reservas,start = 1996,frequency = 12)
plot.ts(reservas[,2], xlab="Año",ylab="Monto",
        main="Reservas Internacionales de Venezuela (millones $)")
```

Reservas Internacionales de Venezuela (millones \$)

Ejemplo 0.3. El archivo “*PreciosPetroleoVzla.xlsx*” contiene el precio promedio mensual de venta para el petróleo venezolano (en dólares) desde enero 2006 hasta noviembre 2017


```
# library(readxl)
petroleo <- read_excel("data/PreciosPetroleoVzla.xlsx")
petroleo=ts(petroleo,start = 2006,frequency = 12)
plot.ts(petroleo[,2], xlab="Año",ylab="Monto",
        main="Precio promedio del petróleo venezolano (en dolares $)")
```

Precio promedio del petróleo venezolano (en dolares \$)

Ejemplo 0.4. El archivo *“IndiceDowJones.xlsx”* contiene los valores histórico del índice Dow-Jones desde enero de 1930 hasta octubre de 2017. En el archivo podems notar que desde enero de 1930 hasta diciembre de 1994, los registros son el promedio semanal, a partir de enero de 1995, los registros son diarios. La primera columna es la fecha, la segunda columna es el valor de apertura, la tercera columna el valor máximo, la cuarta el valor mínimo, la quinta el último valor del índice o valor de cierre y la sexta columna es el volumen de acciones.


```
DJ=read_excel("data/IndiceDowJones.xlsx")
DJ=ts(DJ)
plot.ts(DJ[,-1], xlab="Días",
        main="Índice Dow-Jones desde enero 1930 hasta octubre 2017")
```

Índice Dow-Jones desde enero 1930 hasta octubre 2017



Ejemplo 0.5. La figura siguiente muestra los porcentajes de cambio diario de la Bolsa de Valores de New York desde el 2 de febrero de 1984 hasta el 31 de diciembre de 1991. Como se ve hay una caída fuerte, esta ocurrió el 19 de octubre de 1987 en $t = 938$. El archivo de datos es “nyse.txt”.

```
NYSE=ts(scan("data/nyse.txt"))
plot(NYSE,xlab="Tiempo",ylab="Porcentaje de cambio, NYSE")
```



0.2.1. Clasificación de las series de tiempo

Como se ha mostrado en los ejemplos anteriores, hay una amplia variedad de series de tiempo que pueden clasificarse en varias categorías desde varios puntos de vista.

- **Series de tiempo continuas y discretas.** Los datos registrados continuamente, por ejemplo, por un dispositivo analógico, se denominan series de tiempo continuas. Por otra parte, los datos observados en ciertos intervalos de tiempo, como la presión atmosférica medida cada hora, se denominan series de tiempo discretas. Existen dos tipos de series de tiempo discretas: una en la que las observaciones de los datos se realizan a intervalos de igual espaciamiento y otra en la que las observaciones de los datos se realizan a intervalos de espaciamiento desigual. Aunque las series de tiempo mostradas en los ejemplos anteriores están conectadas continuamente por líneas sólidas, todas ellas son series de tiempo discretas. A partir de ahora en este libro, consideramos sólo discretas series de tiempo grabadas a intervalos igualmente espaciados, porque las series de tiempo que analizamos en ordenadores digitales son generalmente series de tiempo discretas.

- **Series de tiempo univariadas y multivariadas.** Las series de tiempo que consisten en una sola observación en cada punto temporal, como se muestran en los ejemplos 1.1, 1.2, 1.3 y 1.5, se denominan series de tiempo univariadas. Por otra parte, las series de tiempo que se obtienen grabando simultáneamente dos o más fenómenos como los ilustrados en el ejemplo 1.4 se denominan series de tiempo multivariadas. Sin embargo, puede ser difícil distinguir entre series de tiempo univariadas y multivariadas desde su naturaleza; más bien, la distinción se hace desde el punto de vista del analista y por varios otros factores, como la restricción de la medición y los conocimientos empíricos o teóricos sobre el tema. Desde el punto de vista del modelado estadístico, la selección de variables en sí misma es un problema importante en el análisis de series de tiempo.
- **Series de tiempo estacionarias y no estacionarias.** Una serie de tiempo es un registro de un fenómeno que varía irregularmente con el tiempo. En el análisis de series de tiempo, las series de tiempo de variación irregular se expresan generalmente mediante modelos estocásticos. En algunos casos, un fenómeno aleatorio puede ser considerado como la realización de un modelo estocástico con una estructura de variación temporal. Estas series de tiempo se denominan series de tiempo estacionarias. El ejemplo 1.5 es un ejemplo típico de una serie de tiempo estacionaria. Por otra parte, si la estructura estocástica de una serie de tiempo cambia con el tiempo, se denomina serie de tiempo no estacionaria. Como ejemplos típicos de series de tiempo no estacionarias, considere la serie en los ejemplos 1.1 a 1.4. Se puede observar que los valores medios cambian a lo largo del tiempo.
- **Series de tiempo gaussianas y no gaussianas.** Cuando una distribución de una serie de tiempo sigue una distribución normal, la serie de tiempo se denomina serie de tiempo gaussiana; de lo contrario, se denomina serie de tiempo no gaussiana. La mayoría de los modelos considerados en este libro son modelos gaussianos, asumiendo que las series de tiempo siguen distribuciones gaussianas. Al igual que en el caso del ejemplo 1.3, el patrón de las series de tiempo es a veces asimétrico, de modo que la

distribución marginal no puede considerarse gaussiana. Incluso en tal situación, podemos obtener una serie de tiempo gaussiana aproximada mediante una transformación de datos apropiada.

- **Series de tiempo lineales y no lineales.** Una serie de tiempo expresable como la salida de un modelo lineal se denomina serie de tiempo lineal. Por el contrario, la salida de un modelo no lineal se denomina serie de tiempo no lineal.
- **Datos faltantes y valores atípicos.** En el modelado de series de tiempo de problemas del mundo real, a veces necesitamos tratar con observaciones faltante y valores atípicos. Algunos valores de las series de tiempo que no se han registrado por algunas razones se denominan observaciones que faltan en las series de tiempo. Los valores atípicos (observaciones exteriores) pueden ocurrir debido al comportamiento extraordinario del objeto, mal funcionamiento del dispositivo de observación o errores en el registro. En los datos de los ejemplos 1.4 y 1.5 se pueden observar datos atípicos. En el ejemplo 1.4 podemos notar caídas en los índices del DowJones y en el ejemplo 1.4 podemos notar una fuerte caída en el porcentaje de cambio de diario ocurrido el 19 de octubre de 1987.

0.3. Componentes de una serie de tiempo

El análisis clásico de las series de tiempo se basa en la suposición de que los valores que toma la variable de observación es la consecuencia de tres componentes, cuya actuación conjunta da como resultado los valores medidos, estos componentes son:

- 1) **Componente de tendencia.** Se puede definir como un cambio a largo plazo que se produce en la relación al nivel medio, o el cambio a largo plazo de la media. La tendencia se identifica con un movimiento suave de la serie a largo plazo.
- 2) **Componente estacional.** Muchas series de tiempo pre-

sentan cierta periodicidad o dicho de otro modo, variación de cierto período (semestral, mensual, etc.). Por ejemplo las Ventas al Detalle en Puerto Rico aumentan por los meses de noviembre y diciembre por las festividades navideñas. Estos efectos son fáciles de entender y se pueden medir explícitamente o incluso se pueden eliminar de la serie de datos, a este proceso se le llama desestacionalización de la serie.

- 3) **Componente aleatoria.** Esta componente no responde a ningún patrón de comportamiento, sino que es el resultado de factores fortuitos o aleatorios que inciden de forma aislada en una serie de tiempo.

De los tres componentes anteriores los dos primeros son componentes determinísticos, mientras que la última es aleatoria.

Los modelos que se utilizan con más frecuencia son:

- **Modelo aditivo:** $X_t = T_t + E_t + \epsilon_t$
- **Modelos multiplicativos:**
 - *Puro:* $X_t = T_t \times E_t \times \epsilon_t$
 - *Mixto:* $X_t = T_t \times E_t + \epsilon_t$

La elección de uno de estos modelos se hará de manera que el modelo seleccionado sea capaz de agrupar las principales características observadas en el gráfico de la serie en estudio.

0.3.1. El Modelo Aditivo de Componentes de Series de Tiempo

Dada una serie $X_t, t = 1, \dots, n$, el *Modelo Aditivo de Componentes* consiste en asumir que X_t se puede descomponer en tres componentes:

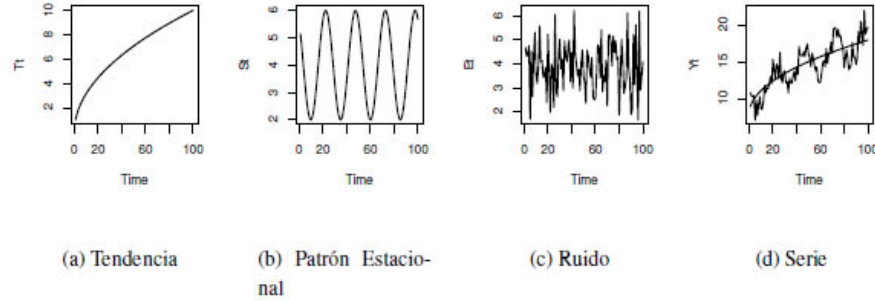
$$X_t = T_t + E_t + \epsilon_t \quad (0.1)$$

donde T_t es la componente de tendencia, E_t es la componente estacional y ϵ_t es la componente aleatoria o de errores. Las componentes T_t y E_t son funciones de t determinísticas. Su evolución es perfectamente predecible.

Este modelo es apropiado cuando la magnitud de la fluctuaciones estacionales de la serie no varía al hacerlo la tendencia.

La componente T_t en algunos casos también puede ser una componente estacional, pero de baja frecuencia, o, equivalentemente, una componente con período muy grande. Por ejemplo, en una serie diaria, E_t puede tener período 30 días, y T_t período 360 días.

En la Figura ?? se muestra la idea de la descomposición. Al superponer las series en los gráficos (a), (b) y (c) se obtiene la serie en el gráfico (d).



Asumiendo el modelo aditivo, el análisis de series de tiempo consiste en modelar y estimar T_t y E_t y luego extraerlas de X_t para obtener $\hat{\epsilon}_t = X_t - \hat{T}_t - \hat{E}_t$. La serie $\hat{\epsilon}_t$ se modela y estima para finalmente reconstruir X_t , $\hat{X}_t = \hat{T}_t + \hat{E}_t + \hat{\epsilon}_t$, y poder realizar el pronóstico $\hat{X}_{t+h} = \hat{T}_{t+h} + \hat{E}_{t+h} + \hat{\epsilon}_{t+h}$, utilizando la información disponible X_t, \dots, X_n con $h = 1, 2, \dots, m$. Sin embargo, puede suceder que la serie $\hat{\epsilon}_t$ sea incorrelacionada, es decir, $Corr(\hat{\epsilon}_t, \hat{\epsilon}_{t+s}) = 0$, para $s \neq 0$. En este caso $\hat{\epsilon}_{t+h} = 0$ para todo $h > 0$.

0.3.2. El Modelo Multiplicativo de Componentes de Series de Tiempo

Dada una serie de tiempo $X_t, t = 1, \dots, n$, el *Modelo Multiplicativo de Componentes* consiste en asumir que X_t se puede descomponer de una de las siguientes maneras:

- *Puro*:

$$X_t = T_t \times E_t \times \epsilon_t \quad (0.2)$$

- *Mixto*:

$$X_t = T_t \times E_t + \epsilon_t \quad (0.3)$$

donde T_t es la componente de tendencia, E_t es la componente estacional y ϵ_t es la componente aleatoria o de errores. Estos modelos son apropiados cuando la magnitud de las fluctuaciones estacionales de la serie crece y decrece proporcionalmente con los crecimientos y decrecimientos de la tendencia respectivamente.

Definición 0.3. La **tendencia**, se define como una función T_t de t que describe la evolución lenta y a largo plazo del nivel medio de la serie. La función T_t depende de parámetros, que deben estimarse.

A continuación presentamos una lista de posibles modelos para la tendencia T_t :

- Lineal

$$T_t = \beta_0 + \beta_1 t \quad (0.4)$$

- Cuadrático

$$T_t = \beta_0 + \beta_1 t + \beta_2 t^2 \quad (0.5)$$

- Cúbico

$$T_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3 \quad (0.6)$$

- Exponencial

$$T_t = \exp(\beta_0 + \beta_1 t) \quad (0.7)$$

- Logístico

$$T_t = \frac{\beta_2}{1 + \beta_1 \exp(-\beta_0 t)} \quad (0.8)$$

En la tendencia cuadrática podemos observar:

- Si $\beta_1, \beta_2 > 0$, T_t es monótona creciente.
- Si $\beta_1, \beta_2 < 0$, T_t es monótona decreciente.
- Si $\beta_1 > 0$ y $\beta_2 < 0$, T_t es cóncava.
- Si $\beta_1 < 0$ y $\beta_2 > 0$, T_t es convexa.

Definición 0.4. (#def:defi-modelo-log-lineal_1) El modelo **Logarítmico Lineal** o **Log-Lineal** se define como

$$\ln X_t = \beta_0 + \beta_1 t + \epsilon_t \quad (0.9)$$

Corresponde a un modelo con tendencia lineal para el logaritmo de X_t . En (0.57) al tomar exponencial se tiene $X_t = \exp(\beta_0 + \beta_1 t + \epsilon_t)$, que es similar al modelo con tendencia exponencial (0.55). Sin embargo, son modelos diferentes y se estiman por métodos diferentes.

0.4. Estimación de la Tendencia

En esta sección introducimos la estimación de la tendencia mediante modelos de regresión lineal y no lineal. Son modelos paramétricos. También introduciremos modelos no paramétricos para estimar la tendencia, como los suavizadores, los filtros lineales y no lineales y las medias móviles. Hay otros métodos que no consideraremos en este curso, por ejemplo, *wavelets*. En ocasiones la expresión “suavizar una serie” es equivalente a “extracción de la tendencia de una serie”, y ambas equivalen a la estimación de la tendencia.

Para la estimación de los parámetros $\beta_0, \beta_1, \beta_2$ en los modelos lineales (0.52), (0.53), (0.54) y (0.57) utilizaremos el método de mínimos cuadrados clásico (MCC). En este método los parámetros

estimados son aquellos que producen el valor mínimo de la suma de errores cuadrados. Para los modelos (0.55) y (0.56) se usa el método de mínimos cuadrados no lineales, que también minimiza la suma de errores cuadrados.

El modelo Log-Lineal (0.57) es equivalente, algebraicamente, a $X_t = \exp(\beta_0 + \beta_1 t + \epsilon_t)$.

Sin embargo, este último modelo es no lineal y no coincide con el modelo exponencial, (0.55), $X_t = \exp(\beta_0 + \beta_1 t) + \epsilon_t$. Es posible estimar por mínimos cuadrados ordinarios el modelo Log-Lineal y utilizar los parámetros estimados $\hat{\beta}_0, \hat{\beta}_1$ como valores iniciales en la estimación del modelo exponencial por mínimos cuadrados no lineales. Pero los parámetros estimados en ambos modelos no necesariamente coinciden.

Aunque la serie tenga una componente estacional E_t , $X_t = T_t + E_t + \epsilon_t$, solamente consideramos un modelo de regresión entre X_t y T_t , tal que $X_t = T_t + \eta_t$, donde η_t es el término de error, de forma que $\eta_t = E_t + \epsilon_t$. Por ejemplo,

1. En el caso lineal $T_t = \beta_0 + \beta_1 t$, ajustamos el modelo de regresión lineal: $X_t = \beta_0 + \beta_1 t + \eta_t$.
2. En el caso cuadrático $T_t = \beta_0 + \beta_1 t + \beta_2 t^2$, ajustamos el modelo de regresión cuadrático $X_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \eta_t$. Nótese que en este caso hay que definir una variable explicativa adicional t^2 .

En general, para que datos de series de tiempo sean estacionarias, es necesario hacer un promedio de productos en el tiempo. Como para datos de serie de tiempo es importante medir la dependencia entre los valores de la serie; al menos, debemos ser capaces de estimar las autocorrelaciones con precisión. Será difícil medir la dependencia de estos valores si la estructura de dependencia no es regular o si cambia en el tiempo. De ahí, que para realizar cualquier análisis estadístico significativo de datos de series de tiempo, será crucial que las funciones de media y autocovarianza satisfagan las condiciones de estacionaridad dadas en la Definición 2.4.2. A menudo, este no es el caso, y en esta sección daremos algunos

métodos para lidiar con los efectos de no-estacionaridad sobre las propiedades estacionarias de las series a estudiar.

Varios de los ejemplos vistos son claramente no estacionarios. La serie Johnson & Johnson en la Figura 2.1 (Tema 2) tiene media que crece exponencialmente en el tiempo, y el incremento de la magnitud de fluctuación alrededor de su tendencia causa que la función de autocovarianza cambie. También, la serie de temperatura global que se muestra en la Figura 2.2 (Tema 2) contiene evidencia de alguna tendencia en el tiempo; el calentamiento global es de forma empírica inducida por el hombre.

Quizás la forma más fácil de trabajar con series no-estacionarias es el modelo de tendencia estacionaria donde el proceso tiene comportamiento estacionario alrededor de una tendencia. Podemos escribir este tipo de modelos como

$$X_t = T_t + Y_t \quad (0.10)$$

donde X_t son las observaciones, T_t denota la tendencia y Y_t es un proceso estacionario.

Por lo general, una tendencia fuerte T_t puede oscurecer el comportamiento del proceso estacionario Y_t , como veremos en ejemplos posteriores. De aquí, será una ventaja el que podamos remover la tendencia como un primer paso para un análisis exploratorio de los datos. Los pasos envuelven obtener un estimador razonable del componente de tendencia, llamémoslo \hat{T}_t y entonces trabajar con el residual

$$\hat{Y}_t = X_t - \hat{T}_t. \quad (0.11)$$

El primer paso en el análisis de cualquier tipo de serie es un gráfico de los datos.

- Si existe alguna aparente discontinuidad en la serie, tal como un cambio súbito en el nivel de la serie, esto puede darnos una idea para el análisis de la serie, un primer paso sería dividir la serie en segmentos homogéneos.

- Si existen observaciones o datos “*outliers*”, estos deben ser estudiados con cuidado para verificar si existe alguna justificación para descartar estas observaciones, como por ejemplo si una observación ha sido registrada de algún otro proceso por error.
- La inspección del gráfico también podría sugerir la representación de los datos como una realización de un proceso, como el modelo clásico de descomposición dado por (0.1).

Si la componente estacional y la componente aleatoria o ruido parecen incrementarse con el nivel del proceso entonces una transformación preliminar de los datos es a menudo usada para hacer que los datos transformados sean compatibles con el modelo (0.1). En esta sección discutiremos algunas técnicas para identificar y eliminar las componentes en @ref(eq:eq-modelo-aditivo}).

Nuestro objetivo es estimar y extraer las componentes determinísticas T_t y E_t con la esperanza de que el residual o la componente aleatoria ϵ_t llegue a ser un proceso estacionario. Entonces podremos usar la teoría de tales procesos para hallar un modelo probabilístico satisfactorio para el proceso ϵ_t , analizar sus propiedades y usarlo en conjunto con T_t y E_t para hacer pronósticos y control de X_t .

Los dos enfoques para la eliminación de las componentes de tendencia y estacional son:

1. Estimación de T_t y E_t en el modelo (0.1),
2. Diferencia de los datos X_t .

Ilustraremos ambos enfoque con varios ejemplos

0.4.1. Eliminación de la tendencia en ausencia de estacionalidad

En ausencia de la componente estacional E_t el modelo (0.1) llega a ser

$$X_t = T_t + \epsilon_t, \quad t = 1, \dots, n \quad (0.12)$$

donde, sin pérdida de generalidad, podemos asumir que $E(\epsilon_t) = 0$.

1. **Método T1: Estimación de T_t por mínimos cuadrados.** En este procedimiento intentamos ajustar una familia paramétrica de funciones como vimos en la sección ??, a los datos eligiendo los parámetros que minimicen $\sum_t (X_t - T_t)^2$.

Ejemplo 0.6. Ajustando una función de la forma (0.53) para la población de los datos en el gráfico ?? para $1790 \leq t \leq 1980$ nos da los parámetros estimados
 $\hat{a}_0 = 2,0978$; $\hat{a}_1 = 2,3349 \times 10^{-3}$; $\hat{a}_2 = 6,4984 \times 10^{-7}$.

En el gráfico ?? se puede observar la curva ajustada y los datos originales. Los valores estimados del proceso de ruido ϵ_t , $1790 \leq t \leq 1980$, son los residuales obtenidos por sustracción de $\hat{T}_t = \hat{a}_0 + \hat{a}_1 t + \hat{a}_2 t^2$ de la serie X_t . La componente de tendencia T_t nos proporciona un predictor natural de los valores futuros de X_t . Por ejemplo si deseamos estimar ϵ_{1990} por su valor medio, obtenemos
 $T_{1990} = 2,7588 \times 10^8$


para la población de EE.UU en 1990. Sin embargo si los residuales $\hat{\epsilon}_t$ están altamente correlacionados podemos ser capaces de usar esos valores para dar una mejor estimación de ϵ_{1990} y por consiguiente de X_{1990} .

```
uspop=ts(scan("data/USPOP.txt"),frequency=1/10,start=1790)
pop=window(uspop,start=1790)
x=time(pop)
reg=lm(pop~x+I(x^2),na.action=NULL)
summary(reg)
```

```
##
## Call:
## lm(formula = pop ~ x + I(x^2), na.action = NULL)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
```

```
## -6947521 -358167 436285 1481410 3391761
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.10e+10  6.59e+08   31.9   <2e-16 ***
## x           -2.34e+07  6.98e+05  -33.5   <2e-16 ***
## I(x^2)       6.51e+03  1.85e+02   35.2   <2e-16 ***
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2770000 on 18 degrees of freedom
## Multiple R-squared:  0.999, Adjusted R-squared:  0.999
## F-statistic: 8.05e+03 on 2 and 18 DF, p-value: <2e-16
```

```
plot(pop,type="o",ylab="Poblacion (millones)")
curve(reg$coefficient[1]+reg$coefficient[2]*x+reg$coefficient[3]*x^2,
      add=T,col= "red")
```



2. **Método T2: Suavizado por medio de un promedio móvil.** Sea q un entero no negativo y consideremos un promedio móvil de la forma

$$W_t = \frac{1}{2q+1} \sum_{j=-q}^q X_{t+j} \quad (0.13)$$

de un proceso $\{X_t\}$ definido por (0.60). Entonces para $q+1 \leq t \leq n-q$,

$$\begin{aligned} W_t &= \frac{1}{2q+1} \sum_{j=-q}^q T_{t+j} + \frac{1}{2q+1} \sum_{j=-q}^q \epsilon_{t+j} \\ &\simeq T_t \end{aligned} \quad (0.14)$$

suponiendo que T_t es aproximadamente lineal sobre el intervalo $[t-q, t+q]$ y que el promedio del término de error sobre este intervalo es cercano a cero.

El promedio móvil entonces nos provee con el estimador

$$\hat{T}_t = \frac{1}{2q+1} \sum_{j=-q}^q X_{t+j}, \quad q+1 \leq t \leq n-q. \quad (0.15)$$


Dado que X_t es no observado para $t \leq 0$ o $t \geq n$ no podemos usar (??) para $t \leq q$ o $t > n-q$. Una forma de resolver este problema es haciendo $X_t = X_1$ para $t < 1$ y $X_t = X_n$ para $t > n$. A continuación presentamos un ejemplo

Ejemplo 0.7. El gráfico siguiente muestra las huelgas ocurridas en EE.UU, de 1951 a 1980, según la Oficina de Estadísticas Laborales del Departamento de Trabajo de los EE.UU.


A estos datos le aplicamos un promedio móvil de 5 puntos, la Figura muestra la serie suavizada y el término de error estimado $\hat{\epsilon}_t = X_t - \hat{T}_t$ se muestra en la Figura ?? . Como era de esperarse ellos no presentan una tendencia clara.

Las instrucciones en R para el suavizado y los gráficos son los siguientes:


```
H=read.table("data/Huelgas.txt")
plot(H,xlab="anos",ylab="Huelgas",type='b')
```



```
W=filter(H[,2],sides=2,rep(1/5,5))  
plot(H[,1],W,xlab="años",ylab="Huelgas",type='b')
```



```
y=H[,2]-W  
plot(H[,1],y,xlab="años",ylab="Residuales",type='b')
```



Para cada valor fijo $a \in [0, 1]$, el promedio móvil de un lado $\hat{T}_t, t = 1, \dots, n$, definido por la recursión

$$\hat{T}_t = aX_t + (1 - a)\hat{T}_t, \quad t = 2, \dots, n \quad (0.16)$$

y

$$\hat{T}_1 = X_1,$$

se puede calcular usando la opción *sides=1* en la función *filter* de R.

Es usual pensar como aplicación de la ecuación (0.66) como un suavizado exponencial, dado que se sigue de la recursión que para $t \leq 2$, $\hat{T}_t = \sum_{j=0}^{t-2} a(1-a)^j X_{t-j} + (1-a)^{t-1} X_1$, es un promedio móvil con peso de X_t, X_{t-1}, \dots , con pesos decreciendo exponencialmente (excepto para el último término).

Es útil pensar en $\{\hat{T}_t\}$ en (*filter*) como un proceso obtenido de $\{X_t\}$ por aplicación de un operador lineal o filtro lineal $\hat{T}_t = \sum_{j=-\infty}^{\infty} a_j X_{t+j}$ con pesos $a_j = (2q+1)^{-1}, -q \leq j \leq q$, y $a_j = 0, |j| > q$. Este filtro particular es un filtro de “paso-bajo” ya que toma los datos $\{X_t\}$ y remueve la componente de rápida fluctuación (o de alta frecuencia) $\{\hat{\epsilon}_t\}$, para dejar el término de la tendencia estimada de lenta variación $\{\hat{T}_t\}$.

- **Método T3: Diferenciación para generar datos estacionarios.** En lugar de intentar remover el ruido por suavizado como en el Método T2, ahora intentaremos eliminar la tendencia por diferenciación. Definamos primero el operador diferencia ∇ por

$$\nabla x_t = x_t - x_{t-1} = (1 - B)x_t, \quad (0.17)$$

donde B es el operador de desplazamiento hacia atrás (*backward shift operator* en inglés),

$$Bx_t = x_{t-1}. \quad (0.18)$$

Las potencias de los operadores B y ∇ se definen de manera obvia, esto es, $B^j(x_t) = x_{t-j}$ y $\nabla^j(x_t) = \nabla(\nabla^{j-1}(x_t))$, $j \geq 1$ con $\nabla^0(x_t) = x_t$. Los polinomios en B y ∇ se manipulan de la misma manera que las funciones polinómicas de variables reales. Por ejemplo

$$\begin{aligned} \nabla^2 x_t &= \nabla(\nabla x_t) = (1 - B)(1 - B)x_t = (1 - 2B + B^2)x_t \\ &= x_t - 2x_{t-1} + x_{t-2}. \end{aligned}$$

Si el operador ∇ se aplica a una función con tendencia lineal $T_t = at + b$, entonces obtenemos la función constante $\nabla T_t = a$. De la misma manera cada tendencia polinomial de grado k se puede reducir a una constante por aplicación del operador ∇^k .

Iniciando entonces con el modelo $X_t = T_t + \epsilon_t$, donde $T_t = \sum_{j=0}^k a_j t^j$ y ϵ_t es estacionario con media cero, obtenemos

$$\nabla^k X_t = k!a_k + \nabla^k \epsilon_t,$$

un proceso estacionario con media $k!a_k$. Esta consideración sugiere la posibilidad, dada una sucesión $\{X_t\}$ de datos, de aplicar el operador ∇ repetidamente hasta conseguir una sucesión $\{\nabla^k X_t\}$ la cual puede ser apropiadamente modelada como una realización de un proceso estacionario. Se encuentra a menudo en la práctica que el orden k de diferenciación es bastante pequeño, frecuentemente uno o dos.⁴

⁴Esto depende del hecho de que muchas funciones pueden ser aproximadas bastante bien, en un intervalo de longitud finita, por un polinomio de grado razonablemente bajo.

Aplicando esta técnica al ejemplo de los 20 datos de población de los EE.UU, hallamos que dos operaciones de diferenciación son suficientes para producir una serie sin aparente tendencia. Los datos diferenciados se muestran en la Figura ?? . Note que la magnitud de las fluctuaciones en $\nabla^2 X_n$ se incrementa con el valor de n . Este efecto se puede suprimir tomando primero logaritmo natural, $y_n = \ln X_n$ y entonces aplicando el operador ∇^2 a la serie $\{y_n\}$.

Las instrucciones en R son las siguientes

```
Dx=diff(uspop,difference=2)
```

0.5. Eliminación de la tendencia y la estacionalidad

Los métodos descritos para remover la tendencia pueden ser adaptados de manera natural para eliminar tanto la tendencia como la estacionalidad en el modelo general

$$X_t = T_t + E_t + \epsilon_t \quad (0.19)$$

donde $E\epsilon_t = 0$, $E_{t+d} = E_t$ y $\sum_{j=1}^d E_t = 0$. Ilustraremos estos métodos con referencia al siguiente ejemplo de accidentes. En la Tabla~?? se muestran los datos, y en la Figura~?? podemos observar que en los mismos se ve claramente una componente estacional con periodo $d = 12$.

| mes/año | 1973 | 1974 | 1975 | 1976 | 1977 | 1978 |
|---------|-------|------|------|------|------|------|
| Ene | 9007 | 7750 | 8162 | 7717 | 7792 | 7836 |
| Feb | 8106 | 6981 | 7306 | 7461 | 6957 | 6892 |
| Mar | 8928 | 8038 | 8124 | 7776 | 7726 | 7791 |
| Abr | 9137 | 8422 | 7870 | 7925 | 8106 | 8129 |
| May | 10017 | 8714 | 9387 | 8634 | 8890 | 9115 |
| Jun | 10826 | 9512 | 9556 | 8945 | 9299 | 9434 |

| mes/año | 1973 | 1974 | 1975 | 1976 | 1977 | 1978 |
|---------|-------|-------|-------|-------|-------|-------|
| Jul | 11317 | 10120 | 10093 | 10078 | 10625 | 10484 |
| Ago | 10744 | 9823 | 9620 | 9179 | 9302 | 9827 |
| Sep | 9713 | 8743 | 8285 | 8037 | 8314 | 9110 |
| Oct | 9938 | 9129 | 8433 | 8488 | 8850 | 9070 |
| Nov | 9161 | 8710 | 8160 | 7874 | 8265 | 8633 |
| Dic | 8927 | 8680 | 8034 | 8647 | 8796 | 9240 |

Accidentes mortales mensuales en EE.UU., años 1973-1978.

Será conveniente para el primer método indexar los datos por año y mes. Entonces $X_{j,k}$, $j = 1, \dots, 6$, $k = 1, \dots, 12$ denotará el número de muertes accidentales reportados para el k -ésimo mes del j -ésimo año, (1972+j). En otras palabras, definimos

$$X_{j,k} = X_{k+12(j-1)}, j = 1, \dots, 6, k = 1, \dots, 12.$$

- **Método E1: Método de la tendencia pequeña.** Si la tendencia es pequeña (como en los datos de accidentes) no es irrazonable suponer que el término de la tendencia es constante, digamos T_j para el año j . Dado que $\sum_{k=1}^{12} E_k = 0$, nos lleva al estimador insesgado natural

$$\hat{T}_j = \frac{1}{12} \sum_{k=1}^{12} X_{j,k}, \quad (0.20)$$

mientras que para E_k , $k = 1, \dots, 12$ tenemos el estimador

$$\hat{E}_t = \frac{1}{6} \sum_{j=1}^6 (X_{j,k} - \hat{T}_j), \quad (0.21)$$

el cual automáticamente satisface el requisito de que $\sum_{k=1}^{12} \hat{E}_k = 0$. El término de error estimado para el mes k del año j es por supuesto

$$\hat{e}_{j,k} = X_{j,k} - \hat{T}_j - \hat{E}_k, \quad j = 1, \dots, 6, k = 1, \dots, 12. \quad (0.22)$$

La generalización de (??) a (??) para datos con estacionalidad con un periodo distinto de 12 es bastante claro.

Las Figuras ??, ?? y ?? muestran respectivamente las observaciones

con la tendencia removida $X_{j,k} - \hat{T}_j$, la componente estacional estimada \hat{E}_t y las observaciones con la tendencia y la estacionalidad removida $\hat{\epsilon}_{j,k} = X_{j,k} - \hat{T}_j - \hat{E}_k$. En la última no se observa una aparente tendencia o estacionalidad.

- **Método E2: Estimación por promedio móvil.** La siguiente técnica es preferible al Método S1 ya que no se basa en la suposición de que T_t es casi constante sobre cada ciclo estacional.

Suponga que tenemos las observaciones $\{x_1, \dots, x_n\}$. Se estima primero la tendencia aplicando un filtro de promedio móvil especialmente elegido para eliminar la componente estacional y para amortiguar el ruido. Si el periodo d es par, digamos $d = 2q$, entonces usamos

$$\hat{T}_t = (0,5x_{t-q} + x_{t-q+1} + \dots + x_{t+q-1} + 0,5x_{t+q})/d, \quad q < t \leq n - q. \quad (0.23)$$

Si el periodo es impar, digamos $d = 2q + 1$, entonces usamos el promedio móvil simple (??). La Figura~?? muestra la tendencia estimada \hat{T}_t para los datos de accidentes mortales obtenido de (??). También muestra la tendencia constante a trozos obtenida por el Método S1.

El segundo paso, es estimar la componente estacional. Para cada $k = 1, \dots, d$, calculamos el promedio w_k de las desviaciones $\{(X_{k+jd} - \hat{T}_{k+jd}) : q < k + jd \leq n - q\}$. Dado que este promedio de desviaciones no necesariamente suma cero, estimamos la componente estacional E_k como

$$\hat{E}_k = w_k - \frac{1}{d} \sum_{i=1}^d w_i, \quad i = 1, \dots, d, \quad (0.24)$$

y $\hat{E}_k = \hat{E}_{k-d}, k > d$.

Los datos sin la componente estacional se definen entonces como la serie original con la componente estacional removida, es decir,

$$d_t = X_t - \hat{E}_t, \quad t = 1, \dots, n. \quad (0.25)$$

Finalmente, reestimamos la tendencia de $\{d_t\}$ aplicando un filtro de promedio móvil como se describió para los datos no estacionales o fijando un polinomio a la serie $\{d_t\}$. El término del ruido estimado llega a ser entonces

$$\hat{\epsilon}_t = X_t - \hat{E}_t - \hat{T}_t, \quad t = 1, \dots, n.$$

Los resultados de aplicar los Métodos S1 y S2 a los datos de accidentes mortales son casi iguales, dado que en este caso la constante a trozos y el promedio móvil de T_t están razonablemente cercanos.

Una comparación de los valores estimados de $E_k, k = 1, \dots, 12$, obtenido con ambos métodos se muestra en la Tabla~??

| k | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 |
|-----------------|-------|-------|------|------|-----|-----|------|-----|------|-----|------|-----|
| $\hat{E}_t(S1)$ | -7434 | -1504 | -724 | -523 | 338 | 808 | 1665 | 961 | -87 | 197 | -321 | -67 |
| $\hat{E}_t(S2)$ | -804 | -1522 | -737 | -526 | 343 | 746 | 1680 | 987 | -109 | 258 | -259 | -57 |

Componentes estacional estimadas para los datos de accidentes mortales

- **Método E3: Diferenciación a paso d.** La técnica de diferenciación la cual aplicamos antes a datos no estacionales se pueden adaptar para lidiar con el caso estacional de periodo d introduciendo el operador de diferencia de paso d ∇_d definido por

$$\nabla_d X_t = X_t - X_{t-d} = (1 - B^d)X_t. \quad (0.26)$$

Este operador no debe confundirse con el operador $\nabla^d = (1 - B)^d$ definido por (??).

Aplicando el operador ∇_d al modelo $X_t = T_t + E_t + \epsilon_t$,

donde $\{E_t\}$ tiene periodo d , obtenemos $\nabla_d X_t = T_t - T_{t-d} + \epsilon_t - \epsilon_{t-d}$,

lo cual nos da una descomposición de la diferencia $\nabla_d X_t$ en una componente de tendencia $(T_t - T_{t-d})$ y un término de ruido $(\epsilon_t - \epsilon_{t-d})$.

La tendencia $(T_t - T_{t-d})$ se puede eliminar usando los métodos ya descritos, por ejemplo, aplicando alguna potencia del operador ∇ . La Figura~?? muestra el resultado de aplicar el operador ∇_{12} a los datos de accidentes mortales. La componente estacional evidente en la Figura~?? está ausente en la Figura de $\nabla_{12}X_t$, $13 \leq t \leq 72$. Sin embargo todavía parece haber una tendencia decreciente. Si ahora aplicamos el operador ∇ a $\nabla_{12}X_t$ y graficamos las diferencias $\nabla\nabla_{12}X_t$, $t = 14, \dots, 72$ obtenemos el gráfico mostrado en la Figura~??, los cuales no tienen una aparente tendencia o componente estacional.

0

Características de series de tiempo

El objetivo primario en el análisis de Series de Tiempo es desarrollar modelos matemáticos que provean una descripción apropiada para los datos muestrales, como los vistos en los ejemplos del capítulo anterior. Así, lo primero que hacemos es utilizar la definición 0.1, para tener un soporte estadístico. En este capítulo daremos algunas definiciones que serán de uso general en todo el resto del libro, también se describirán algunos métodos para el análisis exploratorio de las series de tiempo

0.6. Medidas de dependencia para series de tiempo

Definición 0.5. Un **proceso estocástico** es una familia de variables aleatorias indexadas $x(\omega, t)$ ó $x_t(\omega)$ donde t pertenece a un conjunto de índices T y ω pertenece a un espacio muestral Ω . Si $t = t^*$ fijo, $x(\omega, t^*)$ es una variable aleatoria. Si $\omega = \omega^*$ fijo, $x(\omega^*, t)$ es una función de t , y se llama una realización del proceso. Una **serie de tiempo** es la realización de un proceso estocástico.

Una descripción completa de una serie de tiempo, observada como una colección de n variables aleatorias en puntos de tiempo enteros arbitrarios t_1, t_2, \dots, t_n , para cada entero positivo n , es proporcionada por la función de distribución conjunta, evaluada como la probabilidad de que los valores de la serie sean conjuntamente menor que n constantes c_1, c_2, \dots, c_n , esto es

$$F(c_1, c_2, \dots, c_n) = P(x_{t_1} \leq c_1, x_{t_2} \leq c_2, \dots, x_{t_n} \leq c_n). \quad (0.27)$$

Desafortunadamente, la función de distribución multidimensional usualmente no se puede escribir fácilmente a menos que las variables aleatorias tengan distribución normal conjunta, en cuyo caso, la ecuación (0.27) llega a ser la distribución normal multivariada usual.

Un caso particular en la cual la función de distribución multidimensional es fácil de escribir, será en el caso de variables aleatorias normal estándar independientes e idénticamente distribuidas, para lo cual la función de distribución se puede expresar como el producto de las distribuciones marginales, es decir,

$$F(c_1, c_2, \dots, c_n) = \prod_{t_1}^n \Phi(c_t) \quad (0.28)$$

donde

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x \text{Exp} \left\{ -\frac{z^2}{2} \right\} dz \quad (0.29)$$

es la función de distribución normal estándar acumulada.

Aunque la función de distribución multidimensional describa los datos completamente, esto es un instrumento poco manejable para mostrar y analizar datos de series de tiempo. La función de distribución (0.27) debe ser evaluada como una función de n argumentos, entonces cualquier graficación de las correspondientes funciones de densidad multivariante es prácticamente imposible. La función de distribución unidimensional

$$F_t(x) = P\{x_t \leq x\}$$

o la correspondiente función de densidad unidimensional

$$f_t(x) = \frac{\partial F_t(x)}{\partial x},$$

cuando existen, a menudo son más útiles para determinar si una coordenada en particular de la serie de tiempo tiene una función de

densidad conocida, como la distribución normal (gaussiana), por ejemplo.

Definición 0.6. La **función de media** es definida como

$$\mu_{xt} = \mathbb{E}(x_t) = \int_{-\infty}^{\infty} x f_t(x) dx, \quad (0.30)$$

en caso de que exista, donde \mathbb{E} denota el operador usual de esperanza. Cuando no haya confusión sobre a que serie de tiempo nos referimos, escribiremos μ_{xt} como μ_t .

Lo importante de comprender sobre μ_t consiste en que es una media teórica para la serie de tiempo en un punto particular, donde la media se asume o calcula sobre todos los posibles eventos que podrían haber producido x_t .

Definición 0.7. La **función de autocovarianza** es definida como producto del segundo momento

$$\gamma_x(s, t) = \mathbb{E}[(x_s - \mu_s)(x_t - \mu_t)], \quad (0.31)$$

para todo t y s . cuando no haya confusión en la existencia sobre a que serie nos referimos, escribiremos $\gamma_x(s, t) = \gamma(s, t)$.

Note que $\gamma_x(s, t) = \gamma_x(t, s)$ para todo los puntos s y t . La función de autocovarianza mide la dependencia lineal entre dos puntos de la misma serie en diferentes tiempos. La autocovarianza (0.31) es el promedio de los productos cruzados relacionado con la densidad conjunta $F(x_s, x_t)$. Es claro que, para $s = t$, la autocovarianza se reduce a la varianza (en el caso finito), dado que

$$\gamma_x(t, t) = \mathbb{E}[(x_t - \mu_t)^2] \quad (0.32)$$

Otro función de medida de tendencia importante es la *función de autocorrelación*.

Definición 0.8. La **función de autocorrelación (ACF)** (ACF, siglas en ingles: Autocorrelation Function) se define como

$$\rho(s, t) = \frac{\gamma(s, t)}{\sqrt{\gamma(s, s)\gamma(t, t)}} \quad (0.33)$$

La *ACF* mide la predictibilidad lineal de una serie de tiempo en tiempo t , digamos x_t usando solo el valor x_s . Es fácil de demostrar que $-1 \leq \rho(s, t) \leq 1$ usando la desigualdad de Cauchy-Schwarz ⁵

Si podemos predecir x_t exactamente de x_s a través de la relación lineal $x_t = \beta_0 + \beta_1 x_s$ entonces la correlación será 1 cuando $\beta_1 > 0$ y -1 cuando $\beta_1 < 0$.

Definición 0.9. La **función de covarianza cruzada** entre dos series x_t y y_t se define como

$$\gamma_{xy}(s, t) = \mathbb{E}[(x_s - \mu_{xs})(y_t - \mu_{yt})] \quad (0.34)$$

Definición 0.10. La **función de correlación cruzada (CCF)** (CCF, siglas en ingles: Cross Correlation Function) es definida como

$$\rho_{xy}(s, t) = \frac{\gamma_{xy}(s, t)}{\sqrt{\gamma_x(s, s)\gamma_y(t, t)}} \quad (0.35)$$

Las definiciones anteriores de funciones de media y varianza son completamente generales. Aunque nosotros no hayamos hecho ninguna suposición especial sobre el comportamiento de las series de tiempo, muchos de los ejemplos precedentes han insinuado que puede existir una especie de regularidad en el comportamiento de las mismas. Introducimos la noción de regularidad que usa el concepto de *estacionaridad*, que ya hemos introducido empíricamente en el apartado 1.2.1 “Clasificación de las series de tiempo”

Formalmente tenemos las siguientes definiciones de estacionaridad

Definición 0.11. Una serie de tiempo **estrictamente estacionaria** es una serie para la cual el comportamiento probabilístico de cada sucesión de valores

⁵Note que la desigualdad de Cauchy-Schwartz implica $|\gamma(s, t)|^2 \leq \gamma(s, s)\gamma(t, t)$.

$$\{x_{t_1}, x_{t_2}, \dots, x_{t_k}\}$$

es idéntico a la serie trasladada en el tiempo

$$\{x_{t_1+h}, x_{t_2+h}, \dots, x_{t_k+h}\}$$

Esto es,

$$P[X_{t_1} \leq c_1, \dots, x_{t_k} \leq c_k] = P[X_{t_1+h} \leq c_1, \dots, x_{t_k+h} \leq c_k] \quad (0.36)$$

para todo $k = 1, 2, \dots$, todo puntos de tiempos t_1, t_2, \dots, t_k y números c_1, c_2, \dots, c_k y todo salto $h = \pm 0, \pm 1, \pm 2, \dots$

Esta definición de estacionaridad es muy fuerte para la mayoría de las aplicaciones prácticas. Por ello necesitamos una versión menos fuerte que imponga menos condiciones sobre las distribuciones de probabilidad, ya que si observamos bien la ecuación (0.36), lo que nos dice la misma es que todas las posibles distribuciones de probabilidad deben ser iguales, lo que como ya indicamos en la práctica es muy difícil de comprobar aún para conjuntos de datos sencillos. La siguiente versión de estacionaridad solo impone condiciones sobre los dos primeros momentos de la serie

Definición 0.12. Una serie de tiempo **débilmente estacionaria** x_t , es un proceso de varianza finita tal que

- 1) la función de media μ_t es constante y no depende del tiempo t ,
- 2) la función de covarianza $\gamma(t, s)$ depende solo de las diferencias de s y t , $|t - s|$.

Por consiguiente, usaremos el término **estacionaridad** para referirnos a estacionaridad débil; si un proceso es estacionario en el sentido estricto usaremos el término *estrictamente estacionario*.

Nota. 1) Si una serie de tiempo es estrictamente estacionaria, entonces todas las funciones de distribución multivariadas para

subconjuntos de variables deben coincidir con sus contrapartes en el conjunto trasladado, para todos los valores del parámetro h . Por ejemplo para $k = 1$ La ecuación (0.36) implica que

$$P\{x_s \leq c\} = P\{x_t \leq c\} \quad (0.37)$$

para cada puntos s y t .

Esta declaración implica, por ejemplo, que si la probabilidad de un valor de una serie de tiempo muestreada cada hora es negativa a la 1:00a.m, la probabilidad a la 10:00a.m. es la misma. Además, si la función de media, μ_t de la serie x_t existe, (0.37) implica que $\mu_s = \mu_t$ para todo s y t , y por consiguiente μ_t debe ser constante.

2) Cuando $k = 2$, podemos escribir la ecuación (0.36) como

$$P\{x_s \leq c_1, x_t \leq c_2\} = P\{x_{s+h} \leq c_1, x_{t+h} \leq c_2\} \quad (0.38)$$

para cada par de puntos s y t y salto h . Entonces, si la función de varianza del proceso existe, (0.38) implica que la función de autocovarianza de la serie x_t satisface $\gamma(s, t) = \gamma(s + h, t + h)$ para todos s y t y salto h .

Podemos interpretar este resultado diciendo que la función de autocovarianza del proceso depende sólo de las diferencias de tiempo entre s y t , y no del tiempo actual.

Es claro de la definición 0.11 de serie estrictamente estacionaria, que una serie de tiempo estrictamente estacionaria con varianza finita, también es una serie estacionaria. El recíproco no es cierto a menos que impongamos condicionaes adicionales. Un importante caso donde estacionaridad implica estricta estacionaridad es el caso de series de tiempo gaussianas.

Ya que la función de media $\mathbb{E}(x_t) = \mu_t$ de una serie de tiempo estacionaria es independiente del tiempo t , escribimos

$$\mu_t = \mu \quad (0.39)$$

Debido a que la función de covarianza de una serie de tiempo estacionaria, $\gamma(s, t)$ en tiempos s y t depende sólo de la diferencia $|s - t|$, podemos simplificar la notación. Sea $s = t + h$, donde h representa el tiempo de traslación o salto, entonces

$$\begin{aligned}\gamma(s, t) &= \mathbb{E}[(x_{t+h} - \mu)(x_t - \mu)] \\ &= \mathbb{E}[(x_h - \mu)(x_0 - \mu)] \\ &= \gamma(h, 0)\end{aligned}\tag{0.40}$$

no depende del argumento de tiempo t ; asumiendo que $\text{Var}(x_t) = \gamma(0, 0) < \infty$. De ahora en adelante, por conveniencia, prescindiremos del segundo argumento de $\gamma(h, 0)$, es decir, la función de covarianza se denotará $\gamma(h)$.

Definición 0.13. La **función de autocovarianza de una serie de tiempo estacionaria** se escribirá como

$$\gamma(h) = \mathbb{E}[(x_{t+h} - \mu)(x_t - \mu)]\tag{0.41}$$

Definición 0.14. La **función de autocorrelación (ACF) de una serie de tiempo estacionaria** será escrita, usando (0.33) como

$$\rho(h) = \frac{\gamma(t+h, t)}{\sqrt{\gamma(t+h, t+h)\gamma(t, t)}} = \frac{\gamma(h)}{\gamma(0)}\tag{0.42}$$

La desigualdad de Cauchy-Schwartz muestra nuevamente que $-1 \leq \rho(h) \leq 1$ para todo h .

** Propiedades de la función de covarianza**

- 1) Para el valor en $h = 0$, la función de autocovarianza

$$\gamma(0) = \mathbb{E}[(x_t - \mu)^2]\tag{0.43}$$

es la varianza de la serie de tiempo; note que la desigualdad de Cauchy-Schwartz implica que $|\gamma(h)| \leq \gamma(0)$.

- 2) La autocovarianza de una serie estacionaria es simétrica respecto al origen, esto es

$$\gamma(h) = \gamma(-h) \quad (0.44)$$

para todo h . Esta propiedad se debe a que trasladar la serie por h significa que

$$\begin{aligned} \gamma(h) &= \gamma(t+h-t) \\ &= \mathbb{E}[(x_{t+h} - \mu)(x_t - \mu)] \\ &= \mathbb{E}[(x_t - \mu)(x_{t+h} - \mu)] \\ &= \gamma(t - (t+h)) \\ &= \gamma(-h) \end{aligned}$$

lo cual muestra como usar la notación para demostrar el resultado.

Definición 0.15. Dos series de tiempo x_t y x_s se dice que son **conjuntamente estacionarias** si cada una de ellas es estacionaria y la función de correlación cruzada

$$\gamma_{xy}(h) = \mathbb{E}[(x_{t+h} - \mu_x)(y_t - \mu_y)] \quad (0.45)$$

es una función sólo del salto h .

Definición 0.16. La **función de correlación cruzada (CCF)** de dos series conjuntamente estacionarias x_t y y_t se define como

$$\rho_{xy}(h) = \frac{\gamma_{xy}(h)}{\sqrt{\gamma_x(0)\gamma_y(0)}} \quad (0.46)$$

De nuevo, tenemos el resultado $-1 \leq \rho_{xy}(h) \leq 1$ lo cual nos permite comparar los valores extremos -1 y 1 cuando vemos la relación entre x_{t+h} y y_t . La función de correlación cruzada satisface

$$\rho_{xy}(h) = \rho_{yx}(-h) \quad (0.47)$$

lo cual se puede demostrar de manera similar que para (0.44).

Ejemplo 0.8 (Estacionaridad conjunta). Considere las series x_t y y_t formadas por las sumas y diferencias de dos valores sucesivos de un ruido blanco respectivamente, esto es

$$x_t = w_t + w_{t-1}$$

y

$$y_t = w_t - w_{t-1}$$

donde w_t son variables aleatorias independientes con media cero y varianza σ_w^2 . Es fácil demostrar que $\gamma_x(0) = \gamma_y(0) = 2\sigma_w^2$ y $\gamma_x(1) = \gamma_x(-1) = \sigma_w^2$, $\gamma_y(1) = \gamma_y(-1) = -\sigma_w^2$. También

$$\begin{aligned}\gamma_{xy}(1) &= \mathbb{E}[(x_{t+1} - 0)(y_t - 0)] \\ &= \mathbb{E}[(w_{t+1} + w_t)(w_t - w_{t-1})] \\ &= \sigma_w^2\end{aligned}$$

porque solo uno de los productos es distinto de cero. Similarmente, $\gamma_{xy}(0) = 0$, $\gamma_{xy}(-1) = -\sigma_w^2$. Usando (??), obtenemos

$$\rho_{xy}(h) = \begin{cases} 0, & h = 0 \\ 1/2, & h = 1 \\ -1/2, & h = -1 \\ 0, & |h| \geq 2 \end{cases}.$$

Claramente, las funciones de autocovarianza y correlación cruzada dependen solo del salto h , por lo tanto las series son conjuntamente estacionarias.

El concepto de estacionaridad débil forma la base para muchos de los análisis realizados con series de tiempo. Las propiedades fundamentales de la media (0.39) y la función de covarianza (0.41) son satisfechas por muchos modelos teóricos que aparecen para generar realizaciones muestrales apropiadas. En los ejemplos ?? y ??, las dos series fueron generadas de forma que fuesen realizaciones estacionarias, y en el ejemplo ?? demostramos que la serie en el ejemplo ?? fue de hecho, débilmente estacionaria. Ambos ejemplos son casos especiales de los llamados procesos lineales.

Definición 0.17. Un **proceso lineal** x_t se define como una combinación lineal de variables aleatorias de ruido blanco w_t , y está dado por

$$x_t = \mu + \sum_{j=-\infty}^{\infty} \psi_j w_{t-j} \quad (0.48)$$

donde los coeficientes satisfacen

$$\sum_{j=-\infty}^{\infty} |\psi_j| < \infty \quad (0.49)$$

Para un proceso lineal, podemos demostrar que la función de autocovarianza está dada por

$$\gamma(h) = \sigma_w^2 \sum_{j=-\infty}^{\infty} \psi_{j+h} \psi_j \quad (0.50)$$

para todo $h \geq 0$; recuerde que $\gamma(-h) = \gamma(h)$. Finalmente como mencionamos anteriormente, un caso importante en el cual una serie débilmente estacionaria es también estrictamente estacionaria es la serie normal o gaussiana.

Definición 0.18. Un proceso $\{x_t\}$, se dice que es un **proceso gaussiano** si el k -ésimo vector dimensional $\hat{x} = (x_{t_1}, x_{t_2}, \dots, x_{t_k})$, para cada conjunto de puntos t_1, t_2, \dots, t_k y cada entero positivo k tiene distribución normal multivariada.

Definiendo $k \times 1$ vector de medias $\hat{\mu} = (\mu_{t_1}, \mu_{t_2}, \dots, \mu_{t_k})'$ y la $k \times k$ matriz de covarianza positiva como $\Gamma = \{\gamma(t_i, t_j); i, j = 1, \dots, k\}$, la función de densidad normal multivariada se puede escribir como

$$f(\hat{x}) = (2\pi)^{-k/2} |\Gamma|^{-1/2} \exp \left\{ -\frac{1}{2} (\hat{x} - \hat{\mu})' \Gamma^{-1} (\hat{x} - \hat{\mu}) \right\} \quad (0.51)$$

donde $|\cdot|$ denota el determinante. Esta distribución forma la base para resolver problemas que envuelven inferencia estadística para series de tiempo. Si una serie de tiempo gaussiana $\{x_t\}$ es

débilmente estacionaria, entonces $\mu_t = \mu$ y $\gamma(t_i, t_j) = \gamma(|t_i - t_j|)$, de modo que el vector $\hat{\mu}$ y la matriz Γ son independientes del tiempo. Este hecho implica que todas las distribuciones finitas, (0.51) de la serie $\{x_t\}$ dependen sólo del salto de tiempo y no del tiempo actual, y por consiguiente la serie debe ser estrictamente estacionaria.

0.7. Estimación de la Tendencia

En esta sección introducimos la estimación de la tendencia. En esencia, existen dos métodos para estimar la tendencia y la componente estacional de una serie de tiempo:

- **Método paramétrico:** Se basa en
 - Proponer modelos paramétricos para expresar la relación que guardan la tendencia y la componente estacional con el tiempo.
 - Ajustar dichos modelos a la serie de tiempo (por ejemplo, a través del método de mínimos cuadrados).
 - Aislar la tendencia y la componente estacional por medio de los modelos ajustados.
- **Método no paramétrico:** Se basa en
 - Asumir “suavidad” en la relación que guardan la tendencia y la componente estacional con el tiempo.
 - Aislar la tendencia y la componente estacional a través de la suavización del gráfico de la serie (aplicando, por ejemplo, filtros de promedios móviles).

Hay otros métodos que no consideraremos en este libro, por ejemplo, *wavelets*. En ocasiones la expresión “suavizar una serie” es equivalente a “extracción de la tendencia de una serie”, y ambas equivalen a la estimación de la tendencia.

A continuación presentamos una lista de posibles modelos para la tendencia T_t :

- Lineal

$$T_t = \beta_0 + \beta_1 t \quad (0.52)$$

- Cuadrático

$$T_t = \beta_0 + \beta_1 t + \beta_2 t^2 \quad (0.53)$$

- Cúbico

$$T_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3 \quad (0.54)$$

- Exponencial

$$T_t = \exp(\beta_0 + \beta_1 t) \quad (0.55)$$

- Logístico

$$T_t = \frac{\beta_2}{1 + \beta_1 \exp(-\beta_0 t)} \quad (0.56)$$

En la tendencia cuadrática podemos observar:

- Si $\beta_1, \beta_2 > 0$, T_t es monótona creciente.
- Si $\beta_1, \beta_2 < 0$, T_t es monótona decreciente.
- Si $\beta_1 > 0$ y $\beta_2 < 0$, T_t es cóncava.
- Si $\beta_1 < 0$ y $\beta_2 > 0$, T_t es convexa.

Otro modelo propuesto para la tendencia es el dado por la siguiente definición.

Definición 0.19. El modelo **Logarítmico Lineal** o **Log-Linear** se define como

$$\ln X_t = \beta_0 + \beta_1 t + \epsilon_t \quad (0.57)$$

El modelo anterior corresponde a un modelo con tendencia lineal para el logaritmo de X_t . En (0.57) al tomar exponencial se tiene $X_t = \exp(\beta_0 + \beta_1 t + \epsilon_t)$, que es similar al modelo con tendencia exponencial (0.55). Sin embargo, son modelos diferentes y se estiman por métodos diferentes.

Para la estimación de los parámetros $\beta_0, \beta_1, \beta_2$ en los modelos lineales (0.52), (0.53), (0.54) y (0.57) utilizaremos el método de mínimos cuadrados clásico (MCC). En este método los parámetros

estimados son aquellos que producen el valor mínimo de la suma de errores cuadrados. Para los modelos (0.55) y (0.56) se usa el método de mínimos cuadrados no lineales, que también minimiza la suma de errores cuadrados.

El modelo Log-Lineal (0.57) es equivalente, algebraicamente, a

$$X_t = \exp(\beta_0 + \beta_1 t + \epsilon_t).$$

Sin embargo, este último modelo es no lineal y no coincide con el modelo exponencial, (0.55), $X_t = \exp(\beta_0 + \beta_1 t) + \epsilon_t$. Es posible estimar por mínimos cuadrados ordinarios el modelo Log-Lineal y utilizar los parámetros estimados $\hat{\beta}_0, \hat{\beta}_1$ como valores iniciales en la estimación del modelo exponencial por mínimos cuadrados no lineales. Pero los parámetros estimados en ambos modelos no necesariamente coinciden.

Aunque la serie tenga una componente estacional E_t , $X_t = T_t + E_t + \epsilon_t$, solamente consideramos un modelo de regresión entre X_t y T_t , tal que $X_t = T_t + \eta_t$, donde η_t es el término de error, de forma que $\eta_t = E_t + \epsilon_t$. Por ejemplo,

1. En el caso lineal $T_t = \beta_0 + \beta_1 t$, ajustamos el modelo de regresión lineal: $X_t = \beta_0 + \beta_1 t + \eta_t$.
2. En el caso cuadrático $T_t = \beta_0 + \beta_1 t + \beta_2 t^2$, ajustamos el modelo de regresión cuadrático $X_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \eta_t$. Nótese que en este caso hay que definir una variable explicativa adicional t^2 .

En general, para que datos de series de tiempo sean estacionarias, es necesario hacer un promedio de productos en el tiempo. Como para datos de serie de tiempo es importante medir la dependencia entre los valores de la serie; al menos, debemos ser capaces de estimar las autocorrelaciones con precisión. Será difícil medir la dependencia de estos valores si la estructura de dependencia no es regular o si cambia en el tiempo. De ahí, que para realizar cualquier análisis estadístico significativo de datos de series de tiempo, será crucial que las funciones de media y autocovarianza satisfagan las

condiciones de estacionaridad dadas en la Definición ???. A menudo, este no es el caso, y en esta sección daremos algunos métodos para lidiar con los efectos de no-estacionaridad sobre las propiedades estacionarias de las series a estudiar.

Quizás la forma más fácil de trabajar con series no-estacionarias es el modelo de tendencia estacionaria donde el proceso tiene comportamiento estacionario alrededor de una tendencia. Podemos escribir este tipo de modelos como

$$X_t = T_t + Y_t \quad (0.58)$$

donde X_t son las observaciones, T_t denota la tendencia y Y_t es un proceso estacionario.

Por lo general, una tendencia fuerte T_t puede oscurecer el comportamiento del proceso estacionario Y_t , como veremos en ejemplos posteriores.

De aquí, será una ventaja el que podamos remover la tendencia como un primer paso para un análisis exploratorio de los datos. Los pasos envuelven obtener un estimador razonable del componente de tendencia, llamémoslo \hat{T}_t y entonces trabajar con el residual

$$\hat{Y}_t = X_t - \hat{T}_t. \quad (0.59)$$

El primer paso en el análisis de cualquier tipo de serie es un gráfico de los datos.

- Si existe alguna aparente discontinuidad en la serie, tal como un cambio súbito en el nivel de la serie, esto puede darnos una idea para el análisis de la serie, un primer paso sería dividir la serie en segmentos homogéneos.
- Si existen observaciones o datos “*outliers*”, estos deben ser estudiados con cuidado para verificar si existe alguna justificación para descartar estas observaciones, como por ejemplo si una observación ha sido registrada de algún otro proceso por error.
- La inspección del gráfico también podría sugerir la representación

de los datos como una realización de un proceso, como el modelo clásico de descomposición dado por (0.1).

Si la componente estacional y la componente aleatoria o ruido parecen incrementarse con el nivel del proceso entonces una transformación preliminar de los datos es a menudo usada para hacer que los datos transformados sean compatibles con el modelo (0.1). En esta sección discutiremos algunas técnicas para identificar y eliminar las componentes en (0.1).

Nuestro objetivo es estimar y extraer las componentes determinísticas T_t y E_t con la esperanza de que el residual o la componente aleatoria ϵ_t llegue a ser un proceso estacionario. Entonces podremos usar la teoría de tales procesos para hallar un modelo probabilístico satisfactorio para el proceso ϵ_t , analizar sus propiedades y usarlo en conjunto con T_t y E_t para hacer pronósticos y control de X_t .

Los dos enfoques para la eliminación de las componentes de tendencia y estacional son:

1. Estimación de T_t y E_t en el modelo (0.1),
2. Diferencia de los datos X_t .

Ilustraremos ambos enfoque con varios ejemplos

0.7.1. Estimación de la tendencia en ausencia de estacionalidad

Si tenemos una serie de tiempo para la cual está ausente la componente estacional E_t el modelo (0.1) llega ser

$$X_t = T_t + \epsilon_t, \quad t = 1, \dots, n \quad (0.60)$$

donde, sin pérdida de generalidad, podemos suponer que $\mathbb{E}(\epsilon_t) = 0$. A continuación vamos a describir tres métodos para estimar la tendencia T_t .

1. **Método T1: Estimación de T_t por mínimos cuadrados.** El objetivo de este método es intentar ajustar

una familia paramétrica de funciones como las vistas en las ecuaciones (0.52) a ??, a los datos eligiendo los parámetros que minimicen $\sum_t (X_t - T_t)^2$. Esto es, asumiendo que $\mathbb{E}(\epsilon_t) = 0$, se tiene

$$\mathbb{E}(X_t) = T_t = f(t)$$

Una suposición común es que la función f depende de ciertos parámetros (desconocidos) β_1, \dots, β_p , es decir,

$$f(t) = f(t; \beta_1, \dots, \beta_p) \quad (0.61)$$


Sin embargo, el *tipo* de función es conocida. Los parámetros β_1, \dots, β_p serán estimados a partir de una realización x_t de la variable aleatoria X_t . La aproximación por *estimación de mínimos cuadrados* $\hat{\beta}_1, \dots, \hat{\beta}_p$ debe satisfacer

$$\sum_t (x_t - f(t; \hat{\beta}_1, \dots, \hat{\beta}_p))^2 = \min_{\beta_1, \dots, \beta_p} \sum_t (x_t - f(t; \beta_1, \dots, \beta_p))^2 \quad (0.62)$$

cuya solución, si existe, es un problema numérico. El valor $\hat{x}_t = f(t; \hat{\beta}_1, \dots, \hat{\beta}_p)$ servirá como una *predicción* de futuros valores x_t . Las diferencias observadas $x_t - \hat{x}_t$ son llamadas *residuales*. Ellas contienen información sobre la bondad de ajuste del modelo a los datos.

Ejemplo 0.9. El archivo “USPOP.txt” contiene la información de la población de Estados Unidos de América desde 1780 hasta 1980 segun el censo poblacional cada 10 años. En el gráfico podemos observar que no existe estacionalidad, por lo que podemos aplicar el método descrito para ajustar la tendencia.

```
uspop=ts(scan("data/USPOP.txt"),frequency=1/10,start=1790)
pop=window(uspop,start=1790)
plot(pop,type="o",ylab="Poblacion (millones)")
```



Podemos notar del gráfico que la tendencia es creciente y parece tener un comportamiento cuadrático, por lo que ajustando una función de la forma (0.53) para la población de los datos USPOP para $1790 \leq t \leq 1980$ nos da los parámetros estimados

$$\hat{a}_0 = 2,101 \times 10^{10}; \quad \hat{a}_1 = -2,338 \times 10^7; \quad \hat{a}_2 = 6,506 \times 10^3$$

En el gráfico siguiente se puede observar la curva ajustada y los datos originales. Los valores estimados del proceso de ruido ϵ_t , $1790 \leq t \leq 1980$, son los residuales obtenidos por sustracción de $\hat{T}_t = \hat{a}_0 + \hat{a}_1 t + \hat{a}_2 t^2$ de la serie X_t . La componente de tendencia T_t nos proporciona un predictor natural de los valores futuros de X_t . Por ejemplo si deseamos estimar T_{1990} por su valor medio, obtenemos


$$T_{1990} = 2,4853 \times 10^8$$

para la población de EE.UU en 1990. Sin embargo si los residuales $\hat{\epsilon}_t$ están altamente correlacionados podemos ser capaces de usar esos valores para dar una mejor estimación de T_{1990} y por consiguiente de X_{1990} .

```
x=time(pop)
reg=lm(pop~x+I(x^2),na.action=NULL)
summary(reg)

##
## Call:
## lm(formula = pop ~ x + I(x^2), na.action = NULL)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6947521 -358167  436285  1481410  3391761
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.10e+10   6.59e+08   31.9   <2e-16 ***
## x           -2.34e+07   6.98e+05  -33.5   <2e-16 ***
## I(x^2)        6.51e+03   1.85e+02   35.2   <2e-16 ***
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2770000 on 18 degrees of freedom
## Multiple R-squared:  0.999, Adjusted R-squared:  0.999
## F-statistic: 8.05e+03 on 2 and 18 DF, p-value: <2e-16

plot(pop,type="o",xlab="Años",ylab="Poblacion (millones)")
lines(reg$fitted.values,col="red")
```



Ejemplo 0.10. El archivo “Population-North-Rhine-Westphalia.txt” contiene la población de la región North-Rhine-Westphalia (Alemania) en millones cada 5 años desde 1935 hasta 1980. Observando el gráfico podemos suponer que la tendencia se puede ajustar por el modelo cúbico (0.54), esto es

$$T_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3$$

El código en R para el gráfico y el ajuste es

```
NRWpop=read.table("data/Population-North-Rhine-Westphalia.txt",
                  header = TRUE)
knitr::kable(head(NRWpop,booktabs=TRUE,
                  caption="Población (en millones) de North-Rhine-Westphalia")
```


| Year | Population |
|------|------------|
| 1935 | 11772 |
| 1940 | 12059 |
| 1945 | 11200 |
| 1950 | 12926 |
| 1955 | 14442 |
| 1960 | 15694 |

```
plot(NRWpop, type = "b", col="blue", xlab = "Años", ylab = "Población (millones)")
# Modelo cúbico
t=NRWpop[,1]
pob=NRWpop[,2]
modelo=lm(pob~t+I(t^2)+I(t^3), na.action = NULL)
summary(modelo)
```

```
##
## Call:
## lm(formula = pob ~ t + I(t^2) + I(t^3), na.action = NULL)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -813.0 -199.2   67.1  275.6  493.8
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.11e+09   5.10e+08   4.13   0.0061 **
## t           -3.23e+06   7.81e+05  -4.14   0.0061 **
## I(t^2)        1.65e+03   3.99e+02   4.14   0.0061 **
## I(t^3)       -2.81e-01   6.79e-02  -4.14   0.0061 **
## ---
## Signif. codes:
##  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 472 on 6 degrees of freedom
## Multiple R-squared:  0.974, Adjusted R-squared:  0.962
## F-statistic: 76.2 on 3 and 6 DF, p-value: 3.63e-05
```



```
lines(t,modelo$fitted.values,col="red")
```



La curva punteada en azul corresponde a los datos originales, la curva en rojo corresponde al ajuste mediante el modelo cúbico.

2. **Método T2: Suavizado por medio de un promedio móvil.** Sea q un entero no negativo y consideremos un promedio móvil de la forma

$$W_t = \frac{1}{2q+1} \sum_{j=-q}^q X_{t+j} \quad (0.63)$$

de un proceso $\{X_t\}$ definido por (0.60). Entonces para $q+1 \leq t \leq n-q$,

$$\begin{aligned} W_t &= \frac{1}{2q+1} \sum_{j=-q}^q T_{t+j} + \frac{1}{2q+1} \sum_{j=-q}^q \epsilon_{t+j} \\ &\simeq T_t \end{aligned} \quad (0.64)$$

suponiendo que T_t es aproximadamente lineal sobre el intervalo

$[t - q, t + q]$ y que el promedio del término de error sobre este intervalo es cercano a cero.

El promedio móvil entonces nos provee con el estimador

$$\hat{T}_t = \frac{1}{2q+1} \sum_{j=-q}^q X_{t+j}, \quad q+1 \leq t \leq n-q. \quad (0.65)$$

Dado que X_t es no observado para $t \leq 0$ o $t \geq n$ no podemos usar (0.65) para $t \leq q$ o $t > n - q$. Una forma de resolver este problema es haciendo $X_t = X_1$ para $t < 1$ y $X_t = X_n$ para $t > n$. A continuación presentamos un ejemplo

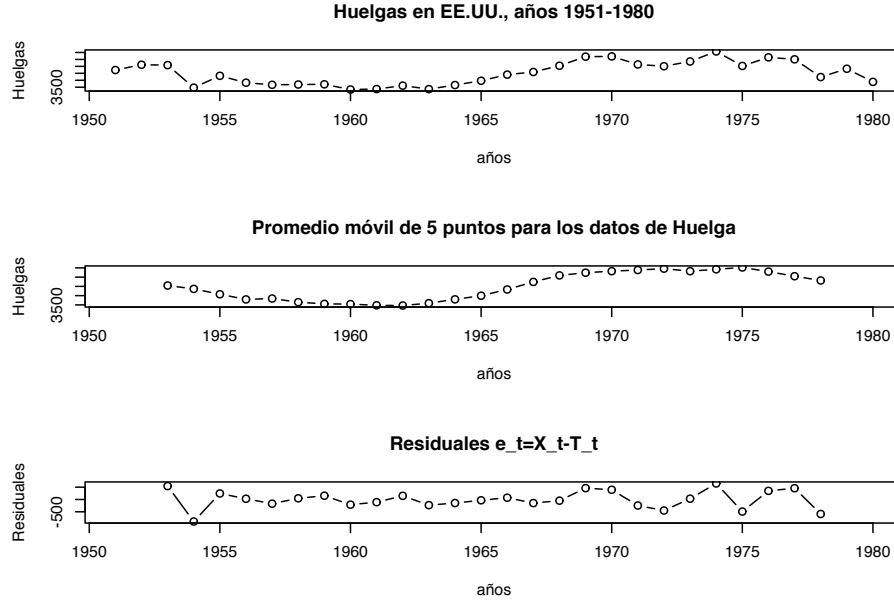
Ejemplo 0.11. El gráfico siguiente muestra las huelgas ocurridas en EE.UU, de 1951 a 1980, según la Oficina de Estadísticas Laborales del Departamento de Trabajo de los EE.UU.

A estos datos le aplicamos un promedio móvil de 5 puntos, la Figura muestra la serie suavizada y el término de error estimado $\hat{\epsilon}_t = X_t - \hat{T}_t$ se muestra en la Figura ?? . Como era de esperarse ellos no presentan una tendencia clara.

Las instrucciones en R para el suavizado y los gráficos son los siguientes:

```
H=read.table("data/Huelgas.txt")
# Promedio móvil por medio de la función "filter"
W=filter(H[,2],sides=2,rep(1/5,5))
# Residuales de  $X_t$ 
y=H[,2]-W
# Graficos
par(mfrow=c(3,1))
plot(H,xlab="años",ylab="Huelgas",type='b',
      main = "Huelgas en EE.UU., años 1951-1980")
plot(H[,1],W,xlab="años",ylab="Huelgas",type='b',
      main = "Promedio móvil de 5 puntos para los datos de Huelga")
```

```
plot(H[,1],y,xlab="años",ylab="Residuales",type='b',
     main = "Residuales e_t=X_t-T_t")
```



Para cada valor fijo $a \in [0, 1]$, el promedio móvil de un lado $\hat{T}_t, t = 1, \dots, n$, definido por la recursión

$$\hat{T}_t = aX_t + (1 - a)\hat{T}_t, \quad t = 2, \dots, n \quad (0.66)$$

y

$$\hat{T}_1 = X_1,$$

se puede calcular usando la opción *sides=1* en la función *filter* de R.

Es usual pensar como aplicación de la ecuación (0.66) como un suavizado exponencial, dado que se sigue de la recursión que para $t \leq 2$, $\hat{T}_t = \sum_{j=0}^{t-2} a(1-a)^j X_{t-j} + (1-a)^{t-1} X_1$, es un promedio móvil

con peso de X_t, X_{t-1}, \dots , con pesos decreciendo exponencialmente (excepto para el último término).

Es útil pensar en $\{\hat{T}_t\}$ en (*filter*) como un proceso obtenido de $\{X_t\}$ por aplicación de un operador lineal o filtro lineal $\hat{T}_t = \sum_{j=-\infty}^{\infty} a_j X_{t+j}$ con pesos $a_j = (2q+1)^{-1}$, $-q \leq j \leq q$, y $a_j = 0$, $|j| > q$. Este filtro particular es un filtro de “paso-bajo” ya que toma los datos $\{X_t\}$ y remueve la componente de rápida fluctuación (o de alta frecuencia) $\{\hat{\epsilon}_t\}$, para dejar el término de la tendencia estimada de lenta variación $\{\hat{T}_t\}$.

3. **Método T3: Diferenciación para generar datos estacionarios.** En lugar de intentar remover el ruido por suavizado como en el Método T2, ahora intentaremos eliminar la tendencia por diferenciación. Definamos primero el operador diferencia ∇ por

$$\nabla x_t = x_t - x_{t-1} = (1 - B)x_t, \quad (0.67)$$

donde B es el operador de desplazamiento hacia atrás (*backward shift operator* en inglés),

$$Bx_t = x_{t-1}. \quad (0.68)$$

Las potencias de los operadores B y ∇ se definen de manera obvia, esto es, $B^j(x_t) = x_{t-j}$ y $\nabla^j(x_t) = \nabla(\nabla^{j-1}(x_t))$, $j \geq 1$ con $\nabla^0(x_t) = x_t$. Los polinomios en B y ∇ se manipulan de la misma manera que las funciones polinómicas de variables reales. Por ejemplo

$$\begin{aligned} \nabla^2 x_t &= \nabla(\nabla x_t) = (1 - B)(1 - B)x_t = (1 - 2B + B^2)x_t \\ &= x_t - 2x_{t-1} + x_{t-2}. \end{aligned}$$

Si el operador ∇ se aplica a una función con tendencia lineal $T_t = at + b$, entonces obtenemos la función constante $\nabla T_t = a$. De la misma manera cada tendencia polinomial de grado k se puede reducir a una constante por aplicación del operador ∇^k .

Iniciando entonces con el modelo $X_t = T_t + \epsilon_t$, donde $T_t = \sum_{j=0}^k a_j t^j$ y ϵ_t es estacionario con media cero, obtenemos

$$\nabla^k X_t = k!a_k + \nabla^k \epsilon_t,$$


un proceso estacionario con media $k!a_k$. Esta consideración sugiere la posibilidad, dada una sucesión $\{X_t\}$ de datos, de aplicar el operador ∇ repetidamente hasta conseguir una sucesión $\{\nabla^k X_t\}$ la cual puede ser apropiadamente modelada como una realización de un proceso estacionario. Se encuentra a menudo en la práctica que el orden k de diferenciación es bastante pequeño, frecuentemente uno o dos.⁶

Ejemplo 0.12. Aplicando esta técnica al ejemplo 0.9 de población de los EE.UU, hallamos que dos operaciones de diferenciación son suficientes para producir una serie sin aparente tendencia. Los datos diferenciados se muestran en la Figura. Note que la magnitud de las fluctuaciones en $\nabla^2 X_n$ se incrementa con el valor de n . Este efecto se puede suprimir tomando primero logaritmo natural, $y_n = \ln X_n$ y entonces aplicando el operador ∇^2 a la serie $\{y_n\}$.

Las instrucciones en R son las siguientes

```
Dx=diff(uspop,difference=2)
plot(Dx,type="b",xlab="Año", ylab="Diferencias")
```

⁶Esto depende del hecho de que muchas funciones pueden ser aproximadas bastante bien, en un intervalo de longitud finita, por un polinomio de grado razonablemente bajo.



0.7.2. Estimación de la tendencia y la estacionalidad

Los métodos descritos para estimar y remover la tendencia pueden ser adaptados de manera natural para estimar tanto la tendencia como la estacionalidad en el modelo general


$$X_t = T_t + E_t + \epsilon_t \quad (0.69)$$

donde $\mathbb{E}(\epsilon_t) = 0$, $E_{t+d} = E_t$ y $\sum_{j=1}^d E_t = 0$. Ilustraremos estos métodos con referencia al siguiente ejemplo de accidentes. El archivo “Accidentes3.txt” muestra el número de accidentes mortales de automóviles mensual ocurridos en EE.UU., entre los años 1973 y 1978. En la tabla siguiente se muestran los datos

```
X<-read.table("data/Accidentes3.txt", header = TRUE)
```

| Mes | X1973 | X1974 | X1975 | X1976 | X1977 | X1978 |
|-----|-------|-------|-------|-------|-------|-------|
| Ene | 9007 | 7750 | 8162 | 7717 | 7792 | 7836 |
| Feb | 8106 | 6981 | 7306 | 7461 | 6957 | 6892 |
| Mar | 8928 | 8038 | 8124 | 7776 | 7726 | 7791 |
| Abr | 9137 | 8422 | 7870 | 7925 | 8106 | 8129 |
| May | 10017 | 8714 | 9387 | 8634 | 8890 | 9115 |
| Jun | 10826 | 9512 | 9556 | 8945 | 9299 | 9434 |

En la figura podemos observar que los datos presentan claramente una componente estacional con periodo $d = 12$.



Será conveniente para el primer método indexar los datos por mes y año. Entonces $X_{j,k}$, $j = 1, \dots, 12$, $k = 1, \dots, 6$ denotará el número de muertes accidentales reportados para el j -ésimo mes del k -ésimo año, $(1972 + k)$. En otras palabras, definimos

$$X_{j,k} = X_{j+12(k-1)}, \quad j = 1, \dots, 12; k = 1, \dots, 6.$$

- 1) **Método E1: Método de la tendencia pequeña.** Si la tendencia es pequeña (como en los datos de accidentes) no es irrazonable suponer que el término de la tendencia es constante, digamos T_k para el año k . Dado que $\sum_{j=1}^{12} E_j = 0$, nos lleva al estimador insesgado natural para la tendencia

$$\hat{T}_k = \frac{1}{12} \sum_{j=1}^{12} X_{j,k}, \quad (0.70)$$

mientras que para la estacionalidad $E_j, j = 1, \dots, 12$ tenemos el estimador

$$\hat{E}_j = \frac{1}{6} \sum_{k=1}^6 (X_{j,k} - \hat{T}_k), \quad (0.71)$$

el cual automáticamente satisface el requisito de que $\sum_{j=1}^{12} \hat{E}_j = 0$. El término de error estimado para el mes j del año k es por supuesto

$$\hat{\epsilon}_{j,k} = X_{j,k} - \hat{T}_k - \hat{E}_j, \quad j = 1, \dots, 12; k = 1, \dots, 6. \quad (0.72)$$

La generalización de (0.70) a (0.72) para datos con estacionalidad con un periodo distinto de 12 es bastante sencillo de realizar, simplemente cambiamos 12 por el correspondiente valor de d . Así, en general, si tenemos n años (meses, semanas, días, etc.) y estacionalidad con periodo d , los estimadores serán:

Para la tendencia T_k :

$$\hat{T}_k = \frac{1}{d} \sum_{j=1}^d X_{j,k} \quad (0.73)$$

Para la estacionalidad E_j :

$$\hat{E}_j = \frac{1}{n} \sum_{k=1}^n (X_{j,k} - \hat{T}_k), \quad j = 1, \dots, d \quad (0.74)$$

Para el error


$$\hat{\epsilon}_{j,k} = X_{j,k} - \hat{T}_k - \hat{E}_j, \quad k = 1, \dots, n; j = 1, \dots, d. \quad (0.75)$$

Las Figuras siguientes muestran respectivamente las observaciones con la tendencia removida $X_{j,k} - \hat{T}_k$, la componente estacional estimada \hat{E}_j y las observaciones con la tendencia y la estacionalidad

removida $\hat{\epsilon}_{j,k} = X_{j,k} - \hat{T}_k - \hat{E}_j$. En la última no se observa una aparente tendencia o estacionalidad.


```
# Estimacion de la tendencia
Tk=numeric(n*d)
for(k in 1:n)
{
  for(j in 1:d)
  {
    Tk[(k-1)*d+j]=Tk[(k-1)*d+j]+(1/12)*X[j,k+1]
  }
}
# Grafico con la tendencia removida
plot(V-Tk,type = "l",xlab = "Meses",ylab = "Num. de accidentes",
     main = "Accidentes mortales mensuales con la tendencia T_k removida")
```

Accidentes mortales mensuales con la tendencia T_k removida




```
# Estimacion de la estacionalidad
Ej=numeric(n*d)
for(j in 1:d)
{
  aux=0
```

```
for(k in 1:n)
{
  aux=aux+(X[j,k+1]-Tk[(k-1)*d+j])
}
for(k in 1:n)
{
  Ej[(k-1)*d+j]=(1/n)*aux
}
}
# Grafico de la estacionalidad
plot(Ej,type = "l",xlab = "Meses",ylab = "Num. de accidentes",
     main = "Estacionalidad de los accidentes mortales mensuales")
```

Estacionalidad de los accidentes mortales mensuales

```
# Estimacion del error
error=V-Tk-Ej
# Grafico del error estimado
plot(error,type = "l",xlab = "Meses",ylab = "Error estimado",
     main = "Error estimado de los accidentes mortales")
grid(col = "darkgray")
```

Error estimado de los accidentes mortales

- 2) **Método E2: Estimación por promedio móvil.** La siguiente técnica es preferible al Método E1 ya que no se basa en la suposición de que T_t es casi constante sobre cada ciclo estacional.

Suponga que tenemos las observaciones $\{x_1, \dots, x_n\}$. Se estima primero la tendencia aplicando un filtro de promedio móvil especialmente elegido para eliminar la componente estacional y para amortiguar el ruido. Si el periodo d es par, digamos $d = 2q$, entonces usamos

$$\hat{T}_t = (0,5x_{t-q} + x_{t-q+1} + \dots + x_{t+q-1} + 0,5x_{t+q})/d, q < t \leq n - q. \quad (0.76)$$

Si el periodo es impar, digamos $d = 2q + 1$, entonces usamos el promedio móvil simple (0.65). La Figura~?? muestra la tendencia estimada \hat{T}_t para los datos de accidentes mortales obtenido de (0.76). También muestra la tendencia constante a trozos obtenida por el Método S1.

El segundo paso, es estimar la componente estacional. Para cada $k = 1, \dots, d$, calculamos el promedio w_k de las desviaciones

$\{(X_{k+jd} - \hat{T}_{k+jd}) : q < k + jd \leq n - q\}$. Dado que este promedio de desviaciones no necesariamente suma cero, estimamos la componente estacional E_k como

$$\hat{E}_k = w_k - \frac{1}{d} \sum_{i=1}^d w_i, \quad i = 1, \dots, d, \quad (0.77)$$

y $\hat{E}_k = \hat{E}_{k-d}, k > d$.

Los datos sin la componente estacional se definen entonces como la serie original con la componente estacional removida, es decir,

$$d_t = X_t - \hat{E}_t, \quad t = 1, \dots, n. \quad (0.78)$$

Finalmente, reestimamos la tendencia de $\{d_t\}$ aplicando un filtro de promedio móvil como se describió para los datos no estacionales o fijando un polinomio a la serie $\{d_t\}$. El término del ruido estimado llega a ser entonces

$$\hat{\epsilon}_t = X_t - \hat{E}_t - \hat{T}_t, \quad t = 1, \dots, n.$$

Los resultados de aplicar los Métodos S1 y S2 a los datos de accidentes mortales son casi iguales, dado que en este caso la constante a trozos y el promedio móvil de T_t están razonablemente cercanos.

Una comparación de los valores estimados de $E_k, k = 1, \dots, 12$, obtenido con ambos métodos se muestra en la Tabla~??

| k | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 |
|-----------------|-------|-------|------|------|-----|-----|------|-----|------|-----|------|-----|
| $\hat{E}_t(S1)$ | -7434 | -1504 | -724 | -523 | 338 | 808 | 1665 | 961 | -87 | 197 | -321 | -67 |
| $\hat{E}_t(S2)$ | -804 | -1522 | -737 | -526 | 343 | 746 | 1680 | 987 | -109 | 258 | -259 | -57 |

Componentes estacional estimadas para los datos de accidentes mortales

■ **Método E3: Diferenciación a paso d.** La técnica de dife-

renciación la cual aplicamos antes a datos no estacionales se pueden adaptar para lidiar con el caso estacional de periodo d introduciendo el operador de diferencia de paso d ∇_d definido por

$$\nabla_d X_t = X_t - X_{t-d} = (1 - B^d)X_t. \quad (0.79)$$

Este operador no debe confundirse con el operador $\nabla^d = (1 - B)^d$ definido por (??).

Aplicando el operador ∇_d al modelo

$$X_t = T_t + E_t + \epsilon_t,$$

donde $\{E_t\}$ tiene periodo d , obtenemos

$$\nabla_d X_t = T_t - T_{t-d} + \epsilon_t - \epsilon_{t-d},$$

lo cual nos da una descomposición de la diferencia $\nabla_d X_t$ en una componente de tendencia $(T_t - T_{t-d})$ y un término de ruido $(\epsilon_t - \epsilon_{t-d})$. La tendencia $(T_t - T_{t-d})$ se puede eliminar usando los métodos ya descritos, por ejemplo, aplicando alguna potencia del operador ∇ . La Figura~?? muestra el resultado de aplicar el operador ∇_{12} a los datos de accidentes mortales. La componente estacional evidente en la Figura~?? está ausente en la Figura de $\nabla_{12}X_t$, $13 \leq t \leq 72$. Sin embargo todavía parece haber una tendencia decreciente. Si ahora aplicamos el operador ∇ a $\nabla_{12}X_t$ y graficamos las diferencias $\nabla \nabla_{12}X_t$, $t = 14, \dots, 72$ obtenemos el gráfico mostrado en la Figura~??, los cuales no tienen una aparente tendencia o componente estacional.

